IMF Smart Education

MÁSTER EN DATA SCIENCE

SISTEMA INTELIGENTE DE APOYO A LA DECISIÓN PARA LA GESTIÓN HÍDRICA AGRÍCOLA

TFM elaborado por: Luis Moreno Díaz · Adrián Pérez Lombal
Manuel Ramos Alascio · Alicia Santamaría Román

Tutor de TFM: Juan Manuel Moreno Lamparero

Madrid, octubre de 2026

Resumen

Este Trabajo Fin de Máster presenta un sistema de apoyo a la decisión para estimar necesidades de riego diarias y semanales. La visión del producto abarca distintos cultivos y zonas, pero el prototipo y su evaluación se limitan al pimiento y a la estación AL01 La Mojonera (Almería), durante la campaña de 2025. La ETL integra observaciones y necesidades de SiAR; una predicción AEMET de 2026 prueba la integración, pero no alimenta el motor evaluado. De 150 fechas observadas, 148 tienen una referencia diaria válida. Seis enfoques se compararon con validación temporal: ningún algoritmo de aprendizaje superó de forma estable a la persistencia. Una vía agronómica que combina ET0 reciente y Kc redujo el MAE a un día un 7 % en desarrollo y un 25 % en el tramo de prueba reutilizado. Son resultados frente al cálculo de SiAR, no demuestran ahorro de agua ni validez para una parcela sin contrastación agronómica y evaluación en campo.

Palabras clave: riego agrícola; sistema de apoyo a la decisión; necesidades hídricas; evapotranspiración; SiAR; series temporales; aprendizaje automático; trazabilidad.

Índice de contenidos

1. Introducción y objetivos 9
1.1. Contexto, motivación y justificación 9
1.2. Objetivos generales y específicos 11
1.3. Alcance, usuarios y limitaciones 12
2. Marco teórico y estado del arte 14
2.1. Necesidades hídricas y gestión eficiente del riego 14
2.2. Agricultura de precisión y Machine Learning 16
2.3. Sistemas inteligentes de apoyo a la decisión 18
3. Metodología y arquitectura del sistema 21
3.1. Fuentes, variables y calidad de los datos 21
3.1.1. Fuentes incorporadas 21
3.1.2. Familias de variables 22
3.1.3. Calidad y trazabilidad 23
3.1.4. Gobierno, seguridad y limitaciones 24
3.2. Arquitectura, tecnologías y flujo de información 24
3.2.1. Capas de la arquitectura 25
3.2.2. Tecnologías y grado de implementación 25
3.2.3. Contratos de datos e integración 26
3.2.4. Reproducibilidad y escalabilidad 27
3.3. Planificación y organización del proyecto 27
4. Procesamiento de datos y Machine Learning 30
4.1. Extracción, transformación y almacenamiento de datos 30
4.1.1. Fuentes utilizadas 31
4.1.2. Configuración dinámica y alcance del piloto 32
4.1.3. Extracción 33
4.1.4. Capa raw 34
4.1.5. Transformación y normalización 35
4.1.6. Tablas interim 35
4.1.7. Volumen antes y después de la limpieza 37

4.1.8. Controles de calidad 38
4.1.9. Almacenamiento y escalabilidad 39
4.1.10. Reproducibilidad y seguridad 40
4.1.11. Limitaciones 40
4.2. Análisis exploratorio y preparación de variables 40
4.2.1. Alcance y unidad de análisis 41
4.2.2. Análisis descriptivo y temporal 42
4.2.3. Relaciones entre variables 44
4.2.4. Preparación y generación de variables 46
4.2.5. Disponibilidad de variables y prevención de fuga de información 46
4.2.6. Estrategia de preparación para el modelado 47
4.2.7. Resultados reproducibles 47
4.3. Desarrollo y evaluación del modelo predictivo 48
4.3.1. Conjunto de modelización y prevención de fuga de información 48
4.3.2. Diseño de validación temporal 48
4.3.3. Enfoques comparados 49
4.3.4. Métricas de evaluación 49
4.3.5. Resultados de validación 50
4.3.6. Evaluación sobre el tramo de prueba 51
4.3.7. Decisión e interpretación 52
4.3.8. Limitaciones y evolución prevista 53
4.3.9. Reproducibilidad y evidencias 53
5. Sistema de recomendación y resultados 54
5.1. Diseño del sistema de recomendación de riego 54
5.1.1. Requisitos de partida 54
5.1.2. Arquitectura del motor 55
5.1.3. Estimación de la necesidad neta 55
5.1.4. Reglas de decisión 56
5.1.5. Estructura de la salida 58
5.1.6. Decisiones descartadas 58

5.2. Aplicación y visualización de resultados 59
5.2.1. Elección de la tecnología de presentación 59
5.2.2. Organización de la interfaz 59
5.2.3. Ejemplo de uso en un cambio de fase del cultivo 60
5.2.4. Uso desde la línea de comandos 62
5.2.5. Visualización de la campaña 63
5.2.6. Limitaciones de la aplicación 63
5.3. Validación, resultados y análisis crítico 63
5.3.1. Fidelidad de la vía agronómica 64
5.3.2. Selección de la ventana de ET0 64
5.3.3. Error de la recomendación a un día 65
5.3.4. Error según el horizonte de planificación 67
5.3.5. Coherencia semanal 68
5.3.6. Sensibilidad a la eficiencia del riego 69
5.3.7. Escenarios de robustez y trazabilidad 69
5.3.8. Rendimiento operativo 71
5.3.9. Análisis crítico 71
5.3.10. Reproducibilidad y evidencias 72
6. Conclusiones 73
6.1. Cumplimiento de objetivos y aportaciones 73
6.1.1. Valoración de los objetivos 73
6.1.2. Aportaciones del trabajo 74
6.2. Limitaciones e impacto del proyecto 76
6.2.1. Limitaciones y alcance de las conclusiones 76
6.2.2. Impacto del proyecto 77
6.3. Mejoras y líneas futuras 78
6.3.1. Ampliación de la evidencia 78
6.3.2. Mejora del motor de recomendación 79
6.3.3. Validación en condiciones de uso 80
6.3.4. Evolución de la plataforma 80

6.3.5. Consideración final 80
Referencias bibliográficas 81
Anexo A. Reproducción y localización de las evidencias 84
A.1. Archivos principales 84
A.2. Secuencia mínima de reproducción 84

Índice de tablas

Tabla 3.1. Fuentes de datos incorporadas y estado de integración. 21
Tabla 3.2. Familias de variables según su disponibilidad y uso. 22
Tabla 3.3. Tecnologías del proyecto y grado de implementación. 25
Tabla 3.4. Fases de trabajo y evidencias de salida. 27
Tabla 4.1. Fuentes oficiales utilizadas y función en el DSS. 30
Tabla 4.2. Parámetros de configuración del caso y datos que dependen de ellos. 32
Tabla 4.3. Registros obtenidos en la primera extracción. 33
Tabla 4.4. Tablas generadas en la capa interim. 35
Tabla 4.5. Ejemplo de la tabla diaria normalizada de SiAR. 35
Tabla 4.6. Ejemplo de la tabla normalizada de necesidades hídricas del pimiento. 36
Tabla 4.7. Ejemplo de la tabla normalizada de predicción diaria de AEMET. 36
Tabla 4.8. Volumen de registros por capa antes y después de la limpieza. 36
Tabla 4.9. Resumen de los controles de calidad por tabla. 38
Tabla 4.10. Cobertura y calidad del conjunto de datos del piloto. 40
Tabla 4.11. Estadísticos descriptivos de las variables principales. 41
Tabla 4.12. Clasificación de variables según su disponibilidad y función en el modelo. 45
Tabla 4.13. Rendimiento medio en los tres cortes de validación temporal. 49
Tabla 4.14. Resultados sobre el periodo de prueba reservado. 50
Tabla 5.1. Reglas aplicadas por el motor de recomendación. 56
Tabla 5.2. Planificación emitida el 28 de junio de 2025 frente a la referencia SiAR. 60
Tabla 5.3. MAE medio de los horizontes 1 a 7 según la ventana de ET0 (mm/día). 63
Tabla 5.4. Error de la recomendación a un día frente a la referencia SiAR. 64
Tabla 5.5. MAE diario según el día del horizonte (mm/día). 66
Tabla 5.6. Dosis bruta de los 148 días con referencia válida según el sistema de riego. 68
Tabla 5.7. Escenarios de validación del comportamiento del sistema. 68
Tabla 6.1. Grado de cumplimiento de los objetivos específicos. 72
Tabla 6.2. Limitaciones del piloto, alcance de las conclusiones y línea de mejora asociada. 76
Tabla A.1. Rutas del repositorio para reproducir y contrastar los resultados. 84

Índice de figuras

Figura 3.1. Arquitectura del prototipo. Las cajas azules representan componentes implementados y las cajas discontinuas identifican extensiones previstas. 24
Figura 4.1. ETL parametrizable desde la selección del usuario hasta la tabla analítica del piloto. Los gráficos inferiores utilizan datos reales de la extracción del 24 de septiembre de 2026. 30
Figura 4.2. Valores ausentes y continuidad del calendario en la tabla analítica del piloto. Fuente: elaboración propia a partir de SiAR. 41
Figura 4.3. Evolución de ET0, ETc, necesidad neta, Kc y precipitación efectiva. Fuente: elaboración propia a partir de SiAR. 42
Figura 4.4. Distribución de temperatura, humedad, ET0 y necesidad neta. Fuente: elaboración propia a partir de SiAR. 43
Figura 4.5. Matriz de correlaciones de Pearson para variables seleccionadas. Fuente: elaboración propia a partir de SiAR. 44
Figura 4.6. Estabilidad temporal de los modelos durante la validación y comparación con la prueba final. 50
Figura 4.7. Predicciones y errores diarios de los seis enfoques en el tramo de prueba. 51
Figura 5.1. Flujo de una consulta en el motor de recomendación. 54
Figura 5.2. Interfaz del DSS para una planificación emitida el 28 de junio de 2025, con la referencia SiAR superpuesta. 60
Figura 5.3. Recomendaciones emitidas cada día con la información del día anterior y error frente a la referencia SiAR. 65
Figura 5.4. MAE diario según el día del horizonte en los periodos de desarrollo y prueba. 66
Figura 5.5. Necesidad neta semanal planificada por el DSS frente a la referencia SiAR y dosis bruta para riego por goteo. 67

1. Introducción y objetivos

1.1. Contexto, motivación y justificación

El agua constituye un factor productivo esencial para la agricultura y, al mismo tiempo, un recurso limitado sometido a una presión creciente. A escala mundial, el regadío concentra alrededor del 70 % de las extracciones de agua dulce y permite obtener cerca del 40 % de la producción agrícola en alrededor del 20 % de la superficie cultivada. Estas cifras muestran la capacidad del riego para estabilizar y elevar la producción, pero también la necesidad de mejorar la productividad del agua y evitar aplicaciones superiores a las necesidades reales de los cultivos (FAO, 2021).

Este reto es especialmente relevante en Europa meridional. La escasez hídrica no se limita a episodios excepcionales de sequía, sino que responde también al desequilibrio recurrente entre la disponibilidad y la demanda de agua. En el conjunto europeo, el estrés hídrico afecta cada año a cerca del 20 % del territorio y al 30 % de la población, con una incidencia más intensa y persistente en el sur del continente (European Environment Agency [EEA], 2021). Además, las proyecciones climáticas anticipan un aumento de los riesgos asociados al calor, la sequía y la reducción de la disponibilidad de agua en la región mediterránea, lo que incrementa la incertidumbre sobre la planificación agrícola y refuerza la necesidad de medidas de adaptación basadas en información actualizada (Intergovernmental Panel on Climate Change [IPCC], 2022).

En España, el regadío presenta una importancia económica desproporcionada respecto a la superficie que ocupa: aproximadamente el 22 % de la superficie cultivada genera alrededor del 65 % de la Producción Final Vegetal. Esta relevancia productiva explica que la política pública no pueda orientarse únicamente a reducir el consumo, sino a compatibilizar la viabilidad de las explotaciones con una aplicación más eficiente del agua y la energía. El marco estatal identifica de forma expresa la digitalización, la adaptación a escenarios de menor disponibilidad hídrica y la tecnificación del regadío como líneas prioritarias de actuación (Real Decreto 854/2022, 2022).

La programación del riego es, por tanto, una decisión compleja y dependiente del contexto. La cantidad de agua que requiere una parcela varía con la especie y la fase fenológica del cultivo, las características del suelo, la localización, la temperatura, la radiación, la humedad, el viento, la precipitación efectiva y la eficiencia del sistema de aplicación. La metodología FAO-56 proporciona una base agronómica consolidada para estimar la evapotranspiración de referencia y transformarla en evapotranspiración del cultivo mediante coeficientes específicos (Allen et al., 1998). Sin embargo, convertir estas estimaciones en una decisión operativa exige disponer de datos consistentes, representativos de la parcela y actualizados con una frecuencia compatible con el horizonte de decisión.

Los enfoques convencionales basados en calendarios fijos, valores medios o reglas generales siguen siendo útiles como referencia, pero pueden responder de forma limitada ante variaciones locales y cambios meteorológicos rápidos. La agricultura de precisión amplía este enfoque al

integrar observaciones meteorológicas, información agrometeorológica, atributos del cultivo y registros históricos. Sobre esta base, las técnicas de aprendizaje automático permiten modelizar relaciones no lineales, comparar patrones y generar predicciones a partir de múltiples variables. La literatura sitúa la gestión del agua y del suelo entre las principales áreas de aplicación del aprendizaje automático en agricultura y destaca su utilidad para generar información de apoyo a la toma de decisiones (Liakos et al., 2018).

El valor práctico de estas técnicas aumenta cuando sus resultados se incorporan a un sistema de apoyo a la decisión, es decir, a una herramienta que transforma datos y predicciones en una recomendación comprensible y accionable. En un estudio desarrollado sobre plantaciones comerciales de cítricos del sureste de España, Navarro-Hellín et al. (2016) integraron variables climáticas, mediciones de suelo y modelos de aprendizaje automático para estimar necesidades semanales de riego y contrastarlas con las decisiones de un experto. Este antecedente respalda la viabilidad del enfoque, pero también muestra que la utilidad de un modelo depende de su calibración local, de la calidad de los datos de entrada y de una validación vinculada al uso real.

El anteproyecto del TFM formuló la visión de un sistema inteligente de apoyo a la decisión para la gestión hídrica agrícola, aplicable a distintos cultivos y localizaciones. Esta memoria distingue esa arquitectura objetivo del piloto construido: un flujo reproducible de observaciones SiAR, comparación predictiva y recomendación para pimiento en AL01 La Mojonera durante 2025. Los indicadores hidrológicos y las predicciones AEMET se estudiaron o extrajeron, pero no sustentan la evaluación del motor. La interfaz facilita la interpretación de resultados orientativos; no sustituye la decisión profesional ni determina por sí sola cuándo regar.

La motivación del proyecto es triple. En primer lugar, responde a una necesidad ambiental y productiva: asignar el agua con mayor precisión en un contexto de escasez y variabilidad climática. En segundo lugar, aborda una necesidad operativa: reducir la dispersión de datos entre fuentes y convertirlos en información útil para decidir cuándo y cuánto regar. En tercer lugar, ofrece un problema adecuado para aplicar de forma integrada competencias de ciencia de datos, como la extracción y transformación de información, el análisis exploratorio, la ingeniería de variables, la comparación de modelos predictivos, la evaluación de errores y la visualización de resultados.

La justificación académica y aplicada del TFM no reside en presuponer que un algoritmo complejo producirá por sí mismo un ahorro determinado. Esa afirmación solo sería defendible después de una validación con datos adecuados y frente a una referencia comparable. La aportación prevista consiste en diseñar y evaluar una cadena completa de datos y decisión, documentar sus supuestos, comparar alternativas de modelización con métricas objetivas y hacer explícitas sus limitaciones. Este planteamiento evita sustituir el criterio agronómico por una salida automática y sitúa el modelo como apoyo trazable a la decisión. De este modo, el proyecto se alinea con las

prioridades de eficiencia, digitalización y adaptación del regadío español, a la vez que mantiene un alcance realista y verificable para un Trabajo Fin de Máster (Real Decreto 854/2022, 2022).

1.2. Objetivos generales y específicos

Objetivo general. El objetivo general del presente Trabajo Fin de Máster es diseñar, implementar y evaluar un sistema inteligente de apoyo a la decisión para la gestión hídrica agrícola que convierta datos agroclimáticos y parámetros de parcela en recomendaciones diarias y semanales comprensibles y trazables. La visión del producto comprende varios cultivos y zonas; el objetivo evaluable de este TFM se restringe a un piloto de una estación, un cultivo y una campaña. La integración hidrológica automática y la decisión sobre el momento de regar requieren datos adicionales.

El sistema se concibe como una herramienta de apoyo y no como un mecanismo autónomo que sustituya el criterio agronómico. En consecuencia, su evaluación no partirá de un porcentaje de ahorro fijado de antemano, sino de resultados verificables: la calidad y trazabilidad de los datos, el rendimiento predictivo frente a referencias comparables, la coherencia de las recomendaciones generadas y la identificación explícita de sus limitaciones.

En cuanto a los objetivos específicos, para alcanzar este propósito se plantea identificar y documentar las fuentes de datos relevantes para el problema, así como las variables meteorológicas, ambientales, agronómicas e hidrológicas necesarias. Esta revisión deberá valorar la disponibilidad de la información, su granularidad temporal y espacial, su consistencia y su utilidad para estimar las necesidades de riego.

Sobre esta base, se pretende diseñar un flujo de datos reproducible que permita extraer, depurar, transformar, integrar y almacenar información procedente de fuentes heterogéneas. El proceso incorporará controles de calidad, criterios de actualización y mecanismos de trazabilidad que permitan conocer el origen y las transformaciones aplicadas a cada dato.

Una vez preparada la información, se realizará un análisis exploratorio y se construirán las variables derivadas necesarias para caracterizar la relación entre las condiciones meteorológicas, el tipo de cultivo, la localización, la disponibilidad de agua y la demanda de riego.

En la fase de modelización, el objetivo será desarrollar y comparar modelos predictivos capaces de estimar las necesidades hídricas o la demanda de riego en el horizonte temporal definido. Para ello se emplearán particiones de entrenamiento y validación adecuadas, junto con métricas objetivas de error y capacidad explicativa.

A partir de las estimaciones obtenidas, se diseñará una lógica de recomendación que las convierta en propuestas sobre la cantidad y el momento de riego. Esta lógica incorporará las restricciones agronómicas y de disponibilidad hídrica que puedan representarse mediante los datos disponibles.

El trabajo también contempla implementar un prototipo de aplicación o panel de visualización que presente las variables relevantes, las predicciones y las recomendaciones de forma clara para agricultores, cooperativas y responsables de explotaciones.

Finalmente, se evaluará el funcionamiento integral del sistema mediante la comparación con referencias agronómicas o modelos base, el análisis de los errores y la revisión de la coherencia práctica de las recomendaciones. Esta evaluación documentará los supuestos, las limitaciones y las condiciones necesarias para una posible aplicación del sistema.

1.3. Alcance, usuarios y limitaciones

El trabajo es una prueba de concepto de un sistema de apoyo a la decisión que conecta adquisición de datos, análisis, comparación de modelos y recomendación. La evaluación empírica se limita al pimiento en la estación AL01 La Mojonera, entre mayo y septiembre de 2025. El diseño permite preparar otros archivos de estación y cultivo, pero la interfaz presentada está fijada al caso piloto y no permite elegirlos. Los resultados no se extrapolan a otros casos.

La fuente de la evaluación es SiAR: sus observaciones agroclimáticas y el CSV de necesidades del pimiento. AEMET OpenData se extrajo y normalizó como prueba de integración, pero sus predicciones de 2026 no coinciden con la campaña de 2025 y no se utilizaron para entrenar ni validar el motor. Los indicadores agregados del Boletín Hidrológico del MITECO se estudiaron y se descartaron como asignación de agua a una parcela; la dotación la introduce el usuario.

El prototipo emite una recomendación diaria o una planificación de hasta siete días. Calcula necesidad neta, dosis bruta según eficiencia y volumen cuando se indica la superficie. Sin balance hídrico del suelo y registro de riegos, no determina el momento óptimo de regar; una lluvia prevista solo produce un aviso. Tampoco acciona bombas, válvulas ni programadores.

Los usuarios principales serán agricultores, técnicos agronómicos, responsables de explotaciones y personal de cooperativas que necesiten consultar de forma integrada las condiciones relevantes para planificar el riego. De manera secundaria, la información agregada podría ser útil para organizaciones del sector o gestores interesados en comparar patrones territoriales, aunque el prototipo no se diseñará como instrumento oficial de asignación de recursos. La literatura sobre herramientas de apoyo a la decisión agrícola señala que la utilidad percibida, la facilidad de uso, la relevancia para el usuario y la confianza en el rendimiento condicionan su adopción, por lo que la interfaz deberá priorizar la claridad y la trazabilidad de las recomendaciones (Rose et al., 2016).

La interfaz implementada permite elegir fecha, horizonte, sistema y eficiencia de riego, superficie y dotación para el caso piloto. La selección de cultivo y localización pertenece a la visión del producto, no a esta versión. La decisión final permanece en manos del usuario, que debe contrastarla con el estado real de la parcela y el criterio agronómico de un profesional.

Las principales limitaciones se relacionan con la calidad y representatividad de los datos. Pueden aparecer valores ausentes, cambios en los formatos, diferencias entre estaciones, retrasos de

actualización y una falta de correspondencia entre la escala de una estación o de una cuenca y las condiciones concretas de una parcela. Además, los datos hidrológicos oficiales pueden ser provisionales y estar sujetos a revisión, y la utilidad de un sistema de riego depende de la calibración local, de la calidad de sus entradas y de una validación vinculada al uso real (MITECO, s. f.; Navarro-Hellín et al., 2016).

El rendimiento del modelo también estará condicionado por la cantidad y diversidad del histórico disponible, la definición de la variable objetivo y la presencia de situaciones climáticas o agronómicas poco representadas durante el entrenamiento. La evaluación utilizará una separación temporal entre entrenamiento y validación y comparará los modelos con referencias agronómicas o modelos base. Este procedimiento permitirá medir el error predictivo y detectar problemas de generalización, pero no equivaldrá a un ensayo de campo controlado ni permitirá atribuir causalmente una reducción del consumo de agua, energía o costes.

Quedan fuera del alcance inicial el control autónomo de infraestructuras de riego, la integración generalizada de sensores privados o imágenes satelitales, la cobertura de todas las cuencas y cultivos de España, la certificación agronómica de las recomendaciones y la prestación de un servicio comercial con garantías de disponibilidad. Estas funcionalidades podrán plantearse como líneas futuras una vez validado el prototipo. De este modo, el alcance se mantiene coherente con los recursos y el calendario de un Trabajo Fin de Máster y permite evaluar de manera verificable la aportación real de la solución.

2. Marco teórico y estado del arte

2.1. Necesidades hídricas y gestión eficiente del riego

La necesidad hídrica de un cultivo expresa la cantidad de agua que debe estar disponible en la zona radicular para sostener sus procesos de evaporación y transpiración durante un periodo determinado. Su componente agronómico principal es la evapotranspiración del cultivo, que integra la evaporación desde el suelo y la transpiración de la planta y suele expresarse como una lámina de agua en milímetros. Esta magnitud no equivale directamente al volumen que debe extraerse o aplicarse mediante riego, porque la necesidad de riego también depende de la precipitación efectiva, del agua almacenada en el suelo y de las pérdidas asociadas al sistema de distribución y aplicación (Allen et al., 1998).

La metodología FAO-56 establece la evapotranspiración de referencia como una medida de la demanda evaporativa de la atmósfera sobre una superficie de referencia. Su estimación mediante el método FAO Penman-Monteith utiliza, entre otras variables, la radiación solar, la temperatura del aire, la humedad y la velocidad del viento. La evapotranspiración del cultivo en condiciones estándar se obtiene combinando esta referencia con un coeficiente de cultivo. Dicho coeficiente varía según la especie, el grado de cobertura del suelo y la fase de desarrollo, por lo que no debe tratarse como un valor fijo durante toda la campaña (Allen et al., 1998).

Notación empleada: ET0 es la evapotranspiración de referencia (mm/día), Kc el coeficiente de cultivo, ETc la evapotranspiración del cultivo y Pe la precipitación efectiva. En el cálculo de referencia: $ETc = Kc \times ET0$; necesidad neta = $\max(ETc - Pe, 0)$. La dosis bruta orientativa se obtiene dividiendo la necesidad neta por la eficiencia de aplicación ηa, expresada entre 0 y 1. Estas ecuaciones no sustituyen un balance de agua del suelo.

Cuando las condiciones reales se apartan de las consideradas estándar, la estimación debe incorporar el efecto del estrés hídrico, la disponibilidad de agua en la zona radicular y las características del manejo. El balance hídrico del suelo permite representar estas relaciones contabilizando las entradas de agua, principalmente la lluvia efectiva y el riego, y las salidas debidas a evapotranspiración, escorrentía y percolación profunda, junto con los cambios en el almacenamiento del suelo. La necesidad neta de riego aparece cuando las aportaciones naturales y la reserva utilizable no permiten cubrir la demanda del cultivo sin superar el agotamiento admisible (Allen et al., 1998).

La programación del riego debe resolver dos decisiones relacionadas: cuándo intervenir y qué cantidad aplicar. El momento depende de la profundidad radicular, de la capacidad del suelo para almacenar agua y de la fracción de agotamiento que el cultivo puede tolerar sin sufrir un estrés relevante. La dosis neta busca reponer el déficit de la zona radicular, mientras que la dosis bruta debe considerar la eficiencia de aplicación del sistema. Una dosis insuficiente puede limitar la

transpiración y el rendimiento; una dosis excesiva puede aumentar la escorrentía, la percolación profunda, el lavado de nutrientes o los problemas de aireación del suelo (Allen et al., 1998).

La gestión eficiente del riego no puede evaluarse mediante un único porcentaje ni deducirse solamente de la tecnología instalada. La eficiencia de conducción describe las pérdidas producidas hasta que el agua llega a la parcela, mientras que la eficiencia de aplicación relaciona el agua almacenada de forma útil en la zona radicular con la aplicada. Además, la uniformidad de distribución indica hasta qué punto la dosis se reparte de manera homogénea. Un sistema puede presentar una eficiencia media aparentemente elevada y, al mismo tiempo, una uniformidad deficiente que genere zonas con déficit y otras con exceso. Por ello, el desempeño debe valorarse con indicadores diferenciados y a la escala espacial adecuada (Burt et al., 1997).

La productividad del agua amplía este análisis al relacionar la producción obtenida con el agua utilizada. Puede expresarse como rendimiento físico o valor económico por unidad de agua, pero su interpretación depende del denominador empleado, que puede ser el agua aplicada, la evapotranspiración o el agua consumida. Una mejora puede proceder de un mayor rendimiento con el mismo consumo o de la reducción de pérdidas no beneficiosas, por lo que la métrica debe especificar la unidad, la escala y el componente del balance hídrico al que se refiere. Sin esta precisión, dos explotaciones o estrategias pueden parecer comparables aunque estén midiendo procesos distintos (Howell, 2001).

También es necesario distinguir entre una reducción del agua aplicada en parcela y un ahorro neto del recurso. Parte de la escorrentía o de la percolación puede retornar al sistema hidrológico y ser reutilizada aguas abajo. En consecuencia, una intervención que reduce estos flujos puede mejorar el funcionamiento de la parcela sin liberar la misma cantidad de agua a escala de cuenca. La evaluación debe separar el uso consuntivo de los flujos recuperables y registrar, cuando sea posible, el agua aplicada, la evapotranspiración del cultivo, los retornos y los cambios en el almacenamiento. Afirmar un ahorro únicamente a partir de una menor dosis aplicada conduciría a una conclusión incompleta (Perry, 2007).

En contextos de escasez puede recurrirse al riego deficitario, entendido como la aplicación deliberada de una cantidad inferior a la requerida para cubrir completamente la evapotranspiración del cultivo. Esta estrategia puede mejorar la productividad del agua, pero su resultado depende de la sensibilidad de cada cultivo y de la fase fenológica en la que se produce el déficit. Por tanto, no debe aplicarse como una reducción uniforme ni considerarse adecuada para cualquier cultivo. Su diseño exige identificar los periodos menos sensibles y cuantificar el posible intercambio entre ahorro de agua, rendimiento y calidad de la producción (Fereres & Soriano, 2007).

Estos fundamentos proporcionan la referencia agronómica del sistema. El piloto utiliza la evapotranspiración de referencia, el coeficiente del cultivo y la precipitación efectiva para aproximar la necesidad neta diaria; no dispone de humedad del suelo ni resuelve su balance hídrico. Por ello, la aplicación calcula una dosis orientativa y no determina de forma autónoma el

momento óptimo de riego. Los modelos de aprendizaje automático se evalúan como alternativas predictivas, sin sustituir la validación agronómica (Allen et al., 1998).

2.2. Agricultura de precisión y Machine Learning

La agricultura de precisión puede definirse como una estrategia de gestión que observa, mide y responde a la variabilidad espacial y temporal de los sistemas productivos. Su rasgo distintivo no es la mera incorporación de tecnología, sino la capacidad de adaptar las decisiones agronómicas a las condiciones concretas de cada zona y momento, en lugar de aplicar una pauta uniforme a toda la explotación. Esta orientación permite asignar los insumos con mayor ajuste a las necesidades del cultivo y constituye una vía relevante para compatibilizar productividad, eficiencia en el uso de los recursos y sostenibilidad (Gebbers & Adamchuk, 2010; Zhang et al., 2002).

Su desarrollo se apoya en tecnologías complementarias, entre ellas los sistemas globales de navegación por satélite, los sistemas de información geográfica, la teledetección, los sensores de suelo y cultivo, la telemetría y los equipos de aplicación a dosis variable. Estas herramientas articulan un ciclo de captura de datos, análisis, prescripción, actuación y evaluación. En este marco, la agricultura inteligente amplía el enfoque al conectar maquinaria, sensores, plataformas digitales y servicios externos, de modo que las decisiones pueden actualizarse de forma continua a partir de información procedente de distintas fuentes (Wolfert et al., 2017; Zhang et al., 2002).

El valor de este enfoque depende de la integración de datos heterogéneos. En una aplicación de riego pueden coexistir registros meteorológicos, propiedades del suelo, información del cultivo, imágenes, mediciones de humedad y antecedentes de manejo. Para que estos datos sean comparables y reutilizables deben conservar marcas temporales, localización, unidades, resolución y procedencia, además de superar controles de calidad. La disponibilidad de un gran volumen de observaciones no garantiza por sí sola conocimiento útil: la interoperabilidad, la gobernanza y la transformación de los datos en información accionable son condiciones necesarias para sostener la toma de decisiones (Wolfert et al., 2017).

El aprendizaje automático aporta métodos capaces de identificar relaciones en esos conjuntos de datos y generar predicciones a partir de ejemplos. En agricultura se han aplicado técnicas supervisadas a problemas de regresión y clasificación, así como técnicas no supervisadas para descubrir agrupaciones, estructuras latentes o anomalías. En el ámbito de este TFM, la regresión resulta pertinente para estimar una variable continua, como la demanda o la dosis de riego, mientras que la clasificación puede representar decisiones discretas y el agrupamiento puede facilitar un análisis exploratorio de campañas, parcelas o condiciones agroclimáticas (Benos et al., 2021; Liakos et al., 2018).

La literatura recoge algoritmos diversos, desde modelos lineales que funcionan como referencia interpretable hasta árboles de decisión, bosques aleatorios, métodos de potenciación, máquinas de vectores soporte y redes neuronales. No existe, sin embargo, un algoritmo universalmente

superior. La selección debe responder al tamaño y la estructura del conjunto de datos, al grado de no linealidad, al coste computacional, a la robustez fuera de muestra y a la necesidad de explicar el resultado. Por ello, una comparación metodológica rigurosa requiere contrastar modelos complejos con líneas base sencillas mediante el mismo esquema de evaluación (Benos et al., 2021; Liakos et al., 2018).

La preparación de los datos y la construcción de variables condicionan de forma decisiva el rendimiento del modelo. Además de tratar valores ausentes, codificar variables categóricas y escalar cuando el algoritmo lo requiera, pueden incorporarse retardos, medias móviles, precipitación acumulada, estacionalidad, localización, tipo de cultivo o fase fenológica. También es posible integrar variables con significado agronómico, como la evapotranspiración de referencia descrita en el apartado anterior. Cada predictor debe estar disponible en el instante real de predicción; utilizar observaciones futuras, datos derivados de la variable objetivo o transformaciones calculadas antes de separar los conjuntos produciría una fuga de información y una evaluación artificialmente optimista (Benos et al., 2021; Roberts et al., 2017).

La validación debe respetar igualmente la estructura del problema. Cuando las observaciones presentan dependencia temporal o espacial, una partición aleatoria puede situar registros muy próximos en entrenamiento y prueba y, con ello, subestimar el error esperado ante periodos o ubicaciones no observados. Para una predicción operativa de riego resulta más coherente entrenar con información del pasado y validar sobre periodos posteriores; si se pretende evaluar la transferencia geográfica, la separación debe realizarse por estaciones, parcelas o zonas. El ajuste de hiperparámetros se efectúa sobre la validación, mientras que el conjunto de prueba final debe permanecer intacto hasta la estimación definitiva del desempeño (Roberts et al., 2017).

Junto con la precisión predictiva, la interpretabilidad es especialmente relevante en un sistema de apoyo a la decisión. Las explicaciones globales permiten conocer qué variables influyen con mayor frecuencia en el comportamiento del modelo, mientras que las explicaciones locales ayudan a entender una recomendación concreta. Métodos como SHAP distribuyen entre las variables la contribución atribuida a cada predicción y facilitan la detección de señales espurias o comportamientos inesperados. Estas atribuciones mejoran la trazabilidad del modelo, aunque no deben interpretarse como prueba de una relación causal (Lundberg & Lee, 2017).

La aplicación práctica también plantea limitaciones. Los cambios de clima, cultivo, manejo o instrumentación pueden alterar la distribución de los datos y degradar el modelo con el tiempo; a ello se añaden fallos de sensores o servicios externos, falta de representatividad de ciertas campañas y dificultades para transferir resultados entre regiones. La propiedad y privacidad de los datos, la interoperabilidad de las plataformas y la capacidad de mantenimiento forman parte, por tanto, de la calidad del sistema y no constituyen aspectos accesorios de su despliegue (Benos et al., 2021; Wolfert et al., 2017).

A partir de estas consideraciones, el componente de aprendizaje automático del presente trabajo se concibe como una extensión evaluable del fundamento agronómico expuesto en el apartado 2.1. Los modelos se compararán con referencias sencillas, se entrenarán únicamente con información disponible en el momento de la predicción y se evaluarán mediante particiones coherentes con la secuencia temporal y, cuando proceda, con la estructura espacial de los datos. La complejidad solo estará justificada si aporta una mejora reproducible fuera de muestra y una explicación compatible con el contexto agronómico. El resultado se integrará como apoyo a la decisión de riego, no como sustitución automática del criterio técnico o del usuario final (Benos et al., 2021; Gebbers & Adamchuk, 2010; Roberts et al., 2017).

2.3. Sistemas inteligentes de apoyo a la decisión

Un sistema de apoyo a la decisión, o DSS por sus siglas en inglés, es un sistema interactivo que organiza información y aplica modelos para ayudar a resolver decisiones semiestructuradas, es decir, problemas en los que una parte puede formalizarse, pero otra depende del contexto y del criterio del usuario. Su finalidad es ampliar la capacidad de análisis y comparar alternativas, no reemplazar al decisor. La consideración de un DSS como inteligente exige que, además de presentar datos, incorpore mecanismos de razonamiento, aprendizaje o conocimiento explícito que adapten la recomendación al caso analizado; este calificativo no implica autonomía ni elimina la supervisión humana (Lindblom et al., 2017; Shim et al., 2002).

La arquitectura habitual puede entenderse mediante tres componentes relacionados. La capa de datos integra observaciones internas y externas con sus metadatos y controles de calidad; la capa de modelos y conocimiento transforma esas entradas mediante cálculos, simulaciones, reglas o algoritmos predictivos; y la capa de interacción permite definir el problema, consultar resultados y comprender los supuestos utilizados. La utilidad del sistema depende de la conexión entre estas capas: un modelo preciso pierde valor si recibe datos desactualizados o si la interfaz no permite interpretar y aplicar su resultado en la explotación (Fountas et al., 2015; Shim et al., 2002).

En la agricultura digital, los DSS pueden combinar sensores de campo, información meteorológica, imágenes, registros históricos y conocimiento agronómico. A partir de estas fuentes ofrecen distintos niveles de apoyo: describen el estado del sistema, detectan desviaciones, anticipan resultados y proponen una actuación sujeta a restricciones. Esta progresión desde la información hasta la recomendación requiere conservar la procedencia de los datos y hacer visibles las condiciones bajo las que se genera cada salida, ya que la integración de tecnologías no garantiza por sí sola una decisión correcta (Zhai et al., 2020).

Un DSS de riego traduce esta arquitectura en un flujo operativo. Primero recibe variables relacionadas con la atmósfera, el suelo y el cultivo; después estima la necesidad hídrica mediante una referencia agronómica, un modelo basado en datos o una combinación de ambos; finalmente presenta una recomendación sobre el momento y la cantidad de agua. Navarro-Hellín et al. (2016) desarrollaron un sistema que integraba mediciones de suelo y variables climáticas, utilizaba

técnicas de aprendizaje automático como motor de inferencia y contrastaba las estimaciones semanales con las decisiones de un experto. El estudio muestra la viabilidad del enfoque, pero también confirma la necesidad de calibración local y validación frente a una referencia aplicable.

La combinación de reglas agronómicas y aprendizaje automático permite aprovechar capacidades diferentes. Los modelos predictivos pueden identificar relaciones difíciles de expresar mediante reglas fijas, mientras que las restricciones explícitas evitan recomendaciones incompatibles con el balance hídrico, la disponibilidad de agua, la fase del cultivo o los límites operativos del sistema de riego. Una arquitectura híbrida también facilita comparar la predicción con una línea base y registrar por qué se ha modificado o descartado una propuesta. De este modo, la recomendación no se reduce a la salida directa de un algoritmo, sino que resulta de un proceso controlado y revisable (Navarro-Hellín et al., 2016; Zhai et al., 2020).

La incertidumbre debe formar parte de la salida del DSS. Los valores ausentes, los retrasos de actualización, los errores de sensores y las diferencias de escala entre una estación, una cuenca y una parcela se propagan hasta la recomendación. Por ello, el sistema debe comprobar la vigencia y cobertura de las entradas, advertir cuando una variable queda fuera del intervalo observado durante el entrenamiento y evitar presentar una estimación puntual como si fuera exacta. Cuando los datos lo permitan, conviene acompañar la recomendación con rangos, escenarios o indicadores de confianza, además de identificar la información que más condiciona el resultado (Fountas et al., 2015; Zhai et al., 2020).

La calidad técnica no garantiza el uso continuado de la herramienta. La investigación sobre DSS agrícolas identifica la facilidad de uso, la relevancia para el problema real, el rendimiento, el coste y la confianza como factores que condicionan su adopción. El diseño centrado en el usuario y la participación de agricultores y asesores durante el desarrollo ayudan a ajustar el vocabulario, la frecuencia de actualización, el nivel de detalle y la forma de presentar las recomendaciones. Esta participación no sustituye la validación técnica, pero reduce el riesgo de construir un sistema correcto desde el punto de vista informático y poco útil en la práctica (Lindblom et al., 2017; Rose et al., 2016).

La evaluación de un DSS debe abarcar dimensiones distintas. En el plano predictivo se analizan los errores y la generalización fuera de muestra; en el plano agronómico se comprueba la coherencia de las recomendaciones y el cumplimiento de restricciones; en el plano operativo se valoran disponibilidad, latencia, trazabilidad y tolerancia a fallos; y en el plano de uso se estudian comprensión, esfuerzo requerido y capacidad para apoyar una decisión real. La historia de los DSS agrícolas muestra que la sofisticación de los modelos no asegura su adopción cuando el sistema no encaja en el contexto sociotécnico de la explotación (McCown, 2002; Rose et al., 2016).

En este TFM, el sistema de apoyo a la decisión conectará las fuentes meteorológicas, agrometeorológicas e hidrológicas definidas en el alcance con la referencia agronómica del

apartado 2.1 y los modelos predictivos descritos en el apartado 2.2. La lógica de recomendación aplicará las restricciones que puedan justificarse con los datos disponibles y mostrará la estimación, las variables relevantes, la vigencia de las entradas y las advertencias necesarias. La interfaz permitirá seleccionar localización y cultivo y consultar el fundamento de la propuesta. El prototipo se considerará inteligente en la medida en que produzca recomendaciones contextualizadas y trazables mediante modelos y reglas; seguirá siendo un instrumento de apoyo, sin accionar infraestructuras ni sustituir el criterio agronómico y la decisión final del usuario (Lindblom et al., 2017; Navarro-Hellín et al., 2016; Zhai et al., 2020).

3. Metodología y arquitectura del sistema

3.1. Fuentes, variables y calidad de los datos

La estrategia de datos distingue entre información observada, predicciones y referencias agronómicas. Esta separación es necesaria para no utilizar como entrada futura una variable que solo se conoce después de la fecha que se desea predecir. También permite explicar el origen de cada recomendación y conservar las respuestas originales para su auditoría.

La visión del producto contempla que el usuario seleccione ubicación, cultivo y periodo; esa interfaz no se ha implementado en el piloto. Esos parámetros determinan la estación SiAR, el municipio AEMET, el calendario de cultivo y los datos que se consultan. Para validar el flujo se fija un piloto reproducible de pimiento al aire libre en Almería, estación AL01 La Mojonera, entre mayo y septiembre de 2025. La web de SiAR identifica el cultivo como Pimiento sin declarar el sistema productivo; su tratamiento como aire libre es una hipótesis de alcance del piloto, coherente con el uso de meteorología y precipitación exterior, pero pendiente de acreditación para el CSV concreto empleado.

3.1.1. Fuentes incorporadas

Tabla 3.1. Fuentes de datos incorporadas y estado de integración.

Fuente y producto	Naturaleza	Información principal	Función en el sistema	Estado
SiAR Web API	Observada	Estaciones, temperatura, humedad, viento, radiación, precipitación, ET0 y precipitación efectiva	Histórico agroclimático y trazabilidad espacial	Integrada y probada.
SiAR, cálculo de necesidades hídricas	Referencia agronómica	Kc, ET0, ETc, precipitación efectiva y necesidad neta por cultivo y zona	Baseline agronómico y etiqueta de referencia del piloto	Incorporada mediante CSV oficial.

Fuente y producto	Naturaleza	Información principal	Función en el sistema	Estado
AEMET OpenData	Predictiva	Predicción municipal diaria y horaria, temperatura, humedad, lluvia, probabilidad, viento y horizonte	Anticipación meteorológica y futura recomendación	Integrada y normalizada; todavía no alineada con el histórico 2025.
MITECO y datos de parcela	Contextual	Disponibilidad de agua, restricciones, suelo, instalación y riego aplicado	Restricciones operativas y validación real	Evolución prevista; no forma parte del conjunto actual.

Los inventarios completos de campos, endpoints, significado y prioridad ya se mantienen en docs/FUENTE_DATOS_SIAR.md y docs/FUENTE_DATOS_AEMET.md. La estrategia de combinación se documenta en docs/ESTRATEGIA_DATOS_DSS.md; por tanto, este apartado resume las decisiones metodológicas sin duplicar esos diccionarios técnicos.

3.1.2. Familias de variables

Tabla 3.2. Familias de variables según su disponibilidad y uso.

Familia	Ejemplos	Disponibilidad	Uso
Identificación y contexto	fuente, estación, municipio, cultivo, fecha y periodo	Conocida antes del cálculo	Claves, selección dinámica y segmentación.
Meteorología observada	temperatura, humedad, viento, radiación, precipitación y ET0	Disponible después de observar el día	Análisis histórico, retardos y validación.
Predicción meteorológica	fecha de emisión, fecha válida, horizonte, lluvia, temperatura, humedad y viento	Disponible antes de la fecha válida	Recomendación futura y análisis de incertidumbre.
Agronómicas	Kc, ETc, precipitación efectiva y necesidad neta	Kc planificado; el resto se calcula u observa	Baseline, diagnóstico y variable objetivo.

Familia	Ejemplos	Disponibilidad	Uso
Temporales y derivadas	día del año, codificación cíclica, retardos y ventanas móviles	Calculadas de forma reproducible	Predictores sin utilizar información futura.
Calidad y trazabilidad	estado, incidencias, fecha de ingesta y archivo de origen	Generadas durante la ETL	Auditoría; no se emplean como predictores.

La variable objetivo del experimento es target_net_irrigation_need_mm, correspondiente a la necesidad neta diaria publicada por SiAR. No representa el riego aplicado ni una respuesta medida de la planta. Los campos contemporáneos que permiten reconstruirla directamente, como ETc y precipitación efectiva del mismo día, se reservan para diagnóstico y se excluyen del entrenamiento predictivo. El catálogo docs/data_samples/feature_catalog_4_2.csv documenta las 88 columnas de la tabla analítica, su tipo, disponibilidad, porcentaje de ausencias, función y riesgo de fuga de información.

3.1.3. Calidad y trazabilidad

Los controles se aplican sin destruir la respuesta original. La capa raw permanece inmutable; las tablas interim añaden tipos, unidades, indicadores de calidad y procedencia; y la capa processed contiene las variables preparadas para análisis y modelado. Los registros con incidencias se conservan y se marcan, en lugar de convertir automáticamente una ausencia en cero.

Se comprueban, al menos, los siguientes aspectos:

1. presencia de variables críticas y validez de tipos;
2. unicidad de las claves lógicas y ausencia de duplicados;
3. continuidad del calendario y cobertura temporal;
4. rangos físicos de temperatura, humedad, viento, radiación y precipitación;
5. coherencia entre temperatura mínima, media y máxima;
6. no negatividad de ET0, precipitación y necesidad hídrica;
7. identidades aproximadas ETc = ET0 × Kc y necesidad_neta = max(ETc − Pe, 0);
8. disponibilidad de cada predictor en el instante de predicción;
9. conservación de fuente, fecha de ingesta y archivo original.

La auditoría reproducible se genera mediante src/analysis/build_etl_audit_4_1.py y queda registrada en docs/data_samples/etl_volume_summary_4_1.csv. Los resultados cuantitativos de la extracción y la limpieza se presentan en el apartado 4.1, mientras que el análisis de distribuciones, ausencias y relaciones entre variables se desarrolla en el apartado 4.2.

3.1.4. Gobierno, seguridad y limitaciones

Las credenciales se leen desde variables de entorno y no se incluyen en Git, los datos ni los mensajes de error. Cada extracción guarda los parámetros de la consulta, la fecha de ingesta y el número de registros. Los archivos raw y las tablas completas generadas se excluyen por defecto del control de versiones. Como excepción documentada, se conserva una instantánea pública y acotada de las entradas del piloto para reproducirlo sin tokens. Se versionan además código, esquemas, metadatos, métricas y figuras reproducibles.

El conjunto actual permite validar el recorrido técnico, pero no demostrar una optimización agronómica generalizable. Solo contiene una estación, un cultivo y una campaña; la referencia SiAR es calculada; y no se dispone todavía de riego real, humedad del suelo, eficiencia de la instalación ni respuesta productiva. Estas limitaciones condicionan la evaluación del capítulo 4 y el alcance de las recomendaciones posteriores.

3.2. Arquitectura, tecnologías y flujo de información

La arquitectura separa adquisición, almacenamiento, transformación, análisis y presentación. Esta división evita que los clientes de las APIs, las reglas de calidad y los modelos queden acoplados a una única interfaz. También permite repetir una fase sin volver a descargar datos ni sobrescribir la evidencia original.



Figura 3.1. Arquitectura del prototipo. Las cajas azules representan componentes implementados y las cajas discontinuas identifican extensiones previstas.

3.2.1. Capas de la arquitectura

1. **Configuración.** La ubicación, el cultivo y el periodo se proporcionan como parámetros de ejecución. En la aplicación del DSS el usuario introduce además la fecha de emisión, el horizonte y los datos de la parcela; el cultivo y la estación quedan fijados por el caso piloto.
2. **Fuentes.** SiAR aporta observaciones y la referencia agronómica; AEMET aporta predicción meteorológica. Cada cliente mantiene autenticación, validación de respuestas y tratamiento de cuotas de forma independiente.
3. **Ingesta.** Los procesos Python descargan los productos y escriben un sobre de trazabilidad con esquema, fuente, parámetros, fecha de ingesta y número de registros.
4. **Almacenamiento por capas.** raw conserva las respuestas; external contiene el CSV agronómico; interim almacena tablas normalizadas y controles de calidad; processed contiene la tabla analítica y las variables derivadas.
5. **Análisis y modelado.** Los módulos de características, análisis exploratorio y evaluación consumen la capa processed. Los modelos se comparan mediante validación temporal y generan métricas, predicciones y figuras.
6. **DSS y presentación.** El motor de recomendación combina la referencia agronómica, la ET0 reciente, el calendario del cultivo y los parámetros de la parcela, aplica un conjunto de reglas explícitas y genera una recomendación diaria y semanal con su explicación. Se consulta mediante una aplicación de demostración en Streamlit o desde la línea de comandos. Su diseño, su funcionamiento y su validación se desarrollan en el capítulo 5.

El flujo principal es unidireccional y reproducible:

```
parámetros -> fuentes -> raw/external -> interim -> processed
        -> análisis/modelos -> evidencias -> motor DSS -> aplicación
```

La procedencia se conserva en sentido inverso: una predicción puede relacionarse con la fila analítica, las tablas normalizadas y el archivo original que la generó.

3.2.2. Tecnologías y grado de implementación

Tabla 3.3. Tecnologías del proyecto y grado de implementación.

Tecnología	Función	Estado en el proyecto
Python	Clientes de APIs, transformación, calidad, características y automatización	Implementado.
pandas y NumPy	Tablas, limpieza, agregación y preparación de variables	Implementado.

Tecnología	Función	Estado en el proyecto
scikit-learn y XGBoost	Pipelines, validación temporal y comparación de modelos	Implementado.
Matplotlib	Figuras reproducibles para análisis y memoria	Implementado.
Streamlit	Aplicación de demostración del sistema de recomendación	Implementado.
Jupyter y Visual Studio Code	Exploración, demostración y desarrollo local	Implementado.
Git y GitHub	Versionado, ramas, revisión e integración del trabajo	Implementado.
MySQL	Persistencia relacional de catálogos, recomendaciones y metadatos	Diseñado, pendiente de implementación.
Apache Hop	Orquestación visual de cargas ETL	Propuesto; el flujo actual se ejecuta con módulos Python.
Power BI o Tableau	Análisis agregado de las recomendaciones archivadas	Opcional; la consulta del prototipo se resuelve con Streamlit.
Docker	Entorno reproducible de servicios y despliegue	Previsto.
PySpark	Procesamiento distribuido si el volumen nacional lo justifica	Condicional; no necesario para el piloto actual.

Esta clasificación actualiza el planteamiento del anteproyecto. MySQL, Apache Hop, Docker, PySpark y un cuadro de mando en Power BI o Tableau forman parte de la arquitectura objetivo, pero no se consideran evidencias terminadas. En el estado actual, el prototipo reproducible se apoya en módulos Python, almacenamiento local por capas y una aplicación en Streamlit para consultar el sistema de recomendación.

3.2.3. Contratos de datos e integración

Cada conjunto dispone de una granularidad y una clave lógica. Las observaciones SiAR se identifican por estación y fecha; las necesidades por estación, cultivo y fecha; y las predicciones

AEMET por municipio, fecha de emisión, horizonte y fecha válida. Las tablas normalizadas utilizan unidades explícitas en los nombres de columnas y fechas ISO 8601.

La unión no se realiza únicamente por coincidencia de nombres. Se conservan los identificadores espaciales y, cuando se incorporen más estaciones, se tendrá en cuenta distancia, altitud, vigencia y cobertura. Una observación y una predicción tampoco se consideran equivalentes: la evaluación futura debe relacionarlas mediante fecha de emisión, fecha válida y horizonte.

3.2.4. Reproducibilidad y escalabilidad

Los procesos se ejecutan mediante módulos independientes y generan salidas deterministas a partir de datos y parámetros conocidos. Las pruebas automáticas cubren construcción de consultas, protección de credenciales, escritura raw, normalización, calidad, características, evaluación temporal y reglas del motor de recomendación, incluida la comprobación de que la planificación no utiliza información posterior a la fecha de emisión. En total, el proyecto dispone de sesenta y una pruebas. Las figuras y resúmenes de la memoria se regeneran desde los mismos archivos que consume el modelado.

La separación por capas permite sustituir progresivamente el almacenamiento local por Parquet, almacenamiento de objetos o MySQL sin cambiar el significado de las variables. La escalabilidad se abordará cuando exista un histórico de varias campañas y estaciones. Para el volumen del piloto, pandas es suficiente y añadir procesamiento distribuido aumentaría la complejidad sin aportar una mejora demostrable.

3.3. Planificación y organización del proyecto

El trabajo sigue un proceso incremental. Cada iteración parte de una necesidad del DSS, identifica los datos requeridos, implementa una transformación o modelo, genera evidencias y revisa las limitaciones antes de integrar el cambio. Esta secuencia permite avanzar desde un piloto acotado sin confundir un prototipo técnico con una solución validada en campo.

Las fases de trabajo son:

Tabla 3.4. Fases de trabajo y evidencias de salida.

Fase	Actividades	Evidencia de salida
Comprensión y alcance	Necesidad de negocio, usuario, decisión y restricciones	Objetivos, alcance del piloto y criterios de evaluación.
Adquisición y comprensión de datos	Inventario de fuentes, extracción y análisis de cobertura	Archivos raw, metadatos, inventarios y controles iniciales.

Fase	Actividades	Evidencia de salida
Preparación	Normalización, calidad, integración y características	Tablas interim y processed, catálogo de variables y auditoría.
Modelado y evaluación	Baselines, modelos, validación temporal y prueba reservada	Métricas, predicciones, figuras y decisión técnica.
Sistema de recomendación	Reglas agronómicas, parámetros de parcela y explicación	Prototipo del DSS y salidas diaria y semanal.
Validación y documentación	Revisión funcional, limitaciones y reproducibilidad	Pruebas, memoria, manual de ejecución y conclusiones.

El historial de Git sitúa los hitos ejecutados: documentación de fuentes y ETL el 24/09/2026; análisis y modelado entre el 28/09 y el 07/10; motor de recomendación y validación el 12/10; conclusiones entre el 15 y el 17/10; revisión de coherencia y reproducción independiente el 22/10. Son fechas de integración comprobables, no una asignación individual de tareas. La publicación de una demo por enlace y una validación agronómica externa siguen pendientes.

El desarrollo se organiza mediante Git y GitHub para mantener trazabilidad sobre el código, la documentación y las evidencias reproducibles. La rama main representa la versión integrada del proyecto. Cada bloque de trabajo se desarrolla en una rama independiente creada desde main, con un nombre que identifica a la persona y la tarea, por ejemplo adrian/procesamiento-ml.

El ciclo habitual comienza actualizando main y creando o recuperando la rama de trabajo. Durante el desarrollo se revisan los archivos modificados, se ejecutan las pruebas asociadas y se crean commits pequeños con mensajes descriptivos. La rama se publica mediante push y se abre una pull request hacia main. Esta solicitud permite revisar el código, las cifras y la documentación antes de la fusión. Después del merge, el resto del equipo actualiza su copia local de main antes de comenzar una nueva tarea.

```
main actualizada
  -> rama persona/tarea
  -> cambios y pruebas locales
  -> commit
  -> push a GitHub
  -> pull request y revisión
  -> merge en main
```

Este flujo separa el trabajo en curso de la versión estable y conserva el histórico de decisiones. Las pull requests indican el apartado del TFM afectado, los archivos modificados, las evidencias

generadas, las pruebas ejecutadas y las limitaciones conocidas. En los cambios de datos se comprueban volúmenes, duplicados, ausencias y trazabilidad. En los cambios de modelado se mantienen la división temporal y el baseline para que las métricas sean comparables.

Antes de integrar una tarea se comprueba que el código se ejecuta desde un entorno limpio, que las pruebas relacionadas finalizan correctamente, que las cifras de la documentación proceden de archivos reproducibles y que no se han incluido credenciales. Los cambios que afecten a la memoria deben mantener la correspondencia entre texto, tablas, figuras y evidencias del repositorio.

Las credenciales se conservan en .env, excluido de Git. Las capas raw, interim y processed también se excluyen por defecto. Una excepción acotada de datos públicos del piloto permite reconstruir la ETL sin tokens; se documenta en docs/REPRODUCCION_PILOTO.md. Se versionan asimismo código, métricas y figuras.

4. Procesamiento de datos y Machine Learning

4.1. Extracción, transformación y almacenamiento de datos

La visión del sistema combina observaciones agroclimáticas con predicciones meteorológicas; el piloto evaluado utiliza las primeras y deja las segundas como prueba de integración. Para ello se ha diseñado un proceso reproducible de extracción, transformación y almacenamiento que mantiene separadas las respuestas originales de las tablas preparadas para el análisis. Esta separación permite auditar cada recomendación, repetir el procesamiento cuando cambien las reglas y evitar que una corrección destruya el contenido recibido de la fuente.

El piloto plantea como referencia el pimiento al aire libre en Almería, con la correspondencia del CSV de SiAR a ese sistema aún pendiente de acreditar. Se ha extraído un ciclo completo del 1 de mayo al 30 de septiembre de 2025 para la estación SiAR AL01 La Mojonera, junto con las necesidades hídricas del pimiento en esa misma estación y periodo. Se obtuvo una predicción de prueba para el municipio AEMET 04013 Almería en 2026; no alimenta la evaluación retrospectiva de 2025. Esta configuración es un caso de validación y no una restricción fija del producto. El diseño conserva identificadores de fuente, estación, municipio, cultivo y tiempo para preparar otros casos; la interfaz actual no ofrece esa selección.

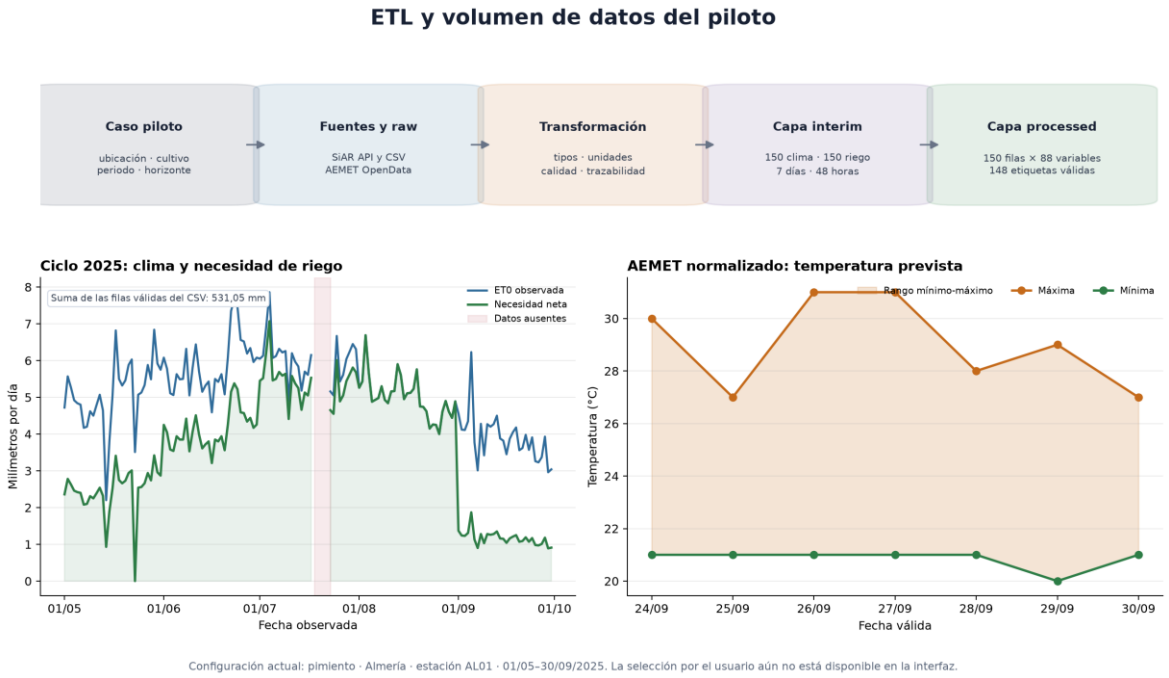


Figura 4.1. ETL del caso piloto desde su configuración hasta la tabla analítica. Los gráficos inferiores utilizan datos reales de la extracción del 24 de septiembre de 2026.

4.1.1. Fuentes utilizadas

Tabla 4.1. Fuentes oficiales utilizadas y función en el DSS.

Organismo y producto	Producto consultado	Datos utilizados	Función en el DSS
MAPA · SiAR	Web API SiAR v1	Observaciones por estación, ET0, precipitación efectiva y catálogos	Histórico agroclimático y trazabilidad espacial.
MAPA · calculadora SiAR	Web de necesidades hídricas	Kc, ET0, ETc, Pe y necesidad neta por cultivo, estación y periodo	Referencia agronómica y variable objetivo del piloto.
AEMET OpenData	AEMET OpenData API	Predicción municipal diaria y horaria	Anticipación meteorológica para recomendaciones futuras.

Las respuestas de la Web API SiAR y AEMET se conservan con su fecha de ingestión, parámetros y archivo de procedencia. El CSV agronómico se acompaña de un fichero de metadatos que identifica organismo, URL, estación, comarca, cultivo, periodo y fecha de descarga.

SiAR

La API del Sistema de Información Agroclimática para el Regadío constituye la fuente histórica principal. Se han incorporado:

- catálogo de estaciones y sus coordenadas, altitud y vigencia;
- catálogo de códigos de validación;
- datos diarios por estación;
- temperatura, humedad, viento, radiación y precipitación;
- evapotranspiración de referencia Penman-Monteith (EtPMon);
- precipitación efectiva calculada (PePMon).

La consulta diaria se realiza con DatosCalculados=true para obtener ET0 y precipitación efectiva junto con las variables meteorológicas observadas. Estos datos representan el entorno de la estación y no una medición directa de la parcela concreta.

AEMET OpenData

AEMET se utiliza como fuente predictiva. Se han incorporado:

- catálogo nacional de municipios;
- inventario de estaciones climatológicas;
- predicción municipal diaria para siete días;
- predicción municipal horaria para aproximadamente 48 horas;
- fecha de elaboración, fecha válida y horizonte de cada predicción;
- temperatura, humedad, precipitación, probabilidad de precipitación, viento, rachas y estado del cielo.

La API de AEMET funciona mediante una descarga en dos pasos. La primera respuesta proporciona una URL temporal oficial y la segunda contiene el JSON meteorológico. El cliente valida el dominio antes de seguir la URL y no transmite la clave en la segunda petición.

Necesidades hídricas de SiAR

La web de SiAR permite descargar CSV con Kc, ET0, ETc, precipitación efectiva y necesidad neta por cultivo y zona. Este producto no dispone de un endpoint público estable en la API documentada. Se ha incorporado el ciclo del pimiento para AL01, con 150 registros entre mayo y septiembre de 2025. El fichero se acompaña de metadatos con la consulta, procedencia, estación, comarca, cultivo y fecha de descarga. Su resultado se utiliza como baseline agronómico y referencia de validación, no como una medición del riego óptimo real.

4.1.2. Configuración dinámica y alcance del piloto

El flujo se ha planteado como una ETL parametrizable. En el producto final, el usuario seleccionará la ubicación de la explotación, el cultivo, el periodo y el horizonte de recomendación. Estos valores determinan las consultas y tablas que se generan:

Tabla 4.2. Parámetros de configuración del caso y datos que dependen de ellos.

Selección	Parámetros derivados	Datos que cambian
Ubicación	estación SiAR y municipio AEMET	Observaciones agroclimáticas y predicciones locales.
Cultivo	comarca, calendario y curva Kc	ETc y necesidad hídrica de referencia.
Periodo	fecha inicial y final	Volumen y campaña histórica descargada.

Selección	Parámetros derivados	Datos que cambian
Horizonte	diario o detalle horario	Producto AEMET y granularidad de la recomendación.

La extracción Python ya admite estación, municipio y fechas mediante parámetros de línea de comandos. La transformación identifica el cultivo, la estación y el periodo a partir del CSV agronómico y sus metadatos. En la configuración actual se fijan Pimiento, Almería, AL01, 04013 y el ciclo de mayo a septiembre de 2025 para disponer de un caso reproducible. La selección automática de todas las combinaciones cultivo-zona y su validación agronómica constituye una fase de ampliación; no se considera ya implementada para todo el territorio nacional.

El flujo lógico es:

```
selección del usuario
  -> cultivo, ubicación, estación, municipio y fechas
  -> extracción de las fuentes correspondientes
  -> normalización y controles de calidad
  -> tabla analítica
  -> predicción y recomendación
```

4.1.3. Extracción

La extracción se implementa en Python mediante clientes independientes para SiAR y AEMET. Las credenciales se leen desde variables de entorno y nunca se escriben en los datos, los mensajes de error o el repositorio.

Cada archivo extraído contiene un sobre de trazabilidad con:

- versión del esquema;
- fuente y conjunto de datos;
- fecha y hora de ingestión;
- parámetros de consulta sin credenciales;
- número de registros;
- respuesta de datos recibida.

La escritura es atómica: primero se genera un archivo temporal y solo se sustituye el destino cuando el JSON está completo. Esto evita archivos parcialmente escritos si se interrumpe el proceso.

La primera ejecución produjo:

Tabla 4.3. Registros obtenidos en la primera extracción.

Fuente	Conjunto	Volumen o cobertura
SiAR	Estaciones	635
SiAR	Códigos de validación	53
SiAR	Histórico diario de AL01, ciclo 2025	150
SiAR web	Necesidades hídricas de pimiento en AL01	150
AEMET	Municipios	8.122
AEMET	Estaciones	926
AEMET	Predicción diaria	7 días
AEMET	Predicción horaria	48 horas

Durante la ejecución se comprobó que el token de SiAR permite un máximo de 100 registros por minuto. Una consulta directa del ciclo completo fue rechazada por superar la cuota. El histórico se divide por ello en bloques máximos de 90 días, con una pausa de 60 segundos entre peticiones. Después se ordenan y deduplican los registros y se escribe un único archivo raw. Los catálogos se descargan de forma independiente y con una frecuencia inferior a las series meteorológicas.

4.1.4. Capa raw

La capa data/raw conserva los JSON sin modificar su estructura interna:

```
data/raw/
├── siar/
│   ├── catalogs/date=AAAA-MM-DD/
│   └── weather/daily/station=AL01/year=AAAA/month=MM/
└── aemet/
    ├── catalogs/date=AAAA-MM-DD/
    └── forecast/
        ├── daily/municipality=04013/ingestion_date=AAAA-MM-DD/
        └── hourly/municipality=04013/ingestion_date=AAAA-MM-DD/
data/external/
└── siar_necesidades_pimiento_AL01_2025.csv
```

La partición por fuente, producto, estación o municipio y fecha permite cargas incrementales. Los raw de trabajo no se publican por defecto. Como excepción se versiona una instantánea pública del piloto con atribución a SiAR y AEMET, suficiente para reconstruir la ETL, la comparación de modelos y la validación del sistema sin credenciales.

4.1.5. Transformación y normalización

El segundo proceso genera tablas planas. Cuando existen varios históricos SiAR o CSV de cultivo exige que se indiquen las rutas, en vez de elegir el archivo más reciente. Antes de integrar comprueba la coincidencia de estación y la intersección de fechas. Las reglas implementadas son:

1. Normalizar nombres en inglés técnico y formato snake_case.
2. Mantener unidades explícitas en los nombres de las columnas.
3. Convertir textos numéricos a valores numéricos sin convertir ausencias en ceros.
4. Transformar fechas a ISO 8601.
5. Normalizar los códigos municipales a cinco posiciones.
6. Conservar el código original cuando AEMET devuelve 4013 en un producto y 04013 en otro.
7. Aplanar las listas horarias para obtener una fila por instante válido.
8. Separar dirección, velocidad y racha del campo heterogéneo vientoAndRachaMax.
9. Asignar las probabilidades por intervalo a cada hora incluida en el periodo.
10. Calcular horizon_days y horizon_hours a partir de la fecha de elaboración.
11. Marcar si una hora seguía siendo futura en el momento de publicación.
12. Conservar archivo y fecha de ingestión como columnas de procedencia.
13. Convertir el CSV agronómico con separador ; y coma decimal sin perder los valores ausentes.
14. Comprobar las identidades $ETc \approx Kc \times ET0$ y necesidad neta $\approx \max(ETc - Pe, 0)$ con tolerancia de redondeo.

No se combinaron las observaciones SiAR de 2025 con las predicciones AEMET emitidas en 2026. Una observación describe lo que ocurrió y una predicción lo que se esperaba en el momento de emisión. Para una evaluación conjunta futura harán falta pronósticos históricos y una unión por fecha válida, emisión y horizonte.

4.1.6. Tablas interim

El proceso genera cinco CSV codificados en UTF-8:

Tabla 4.4. Tablas generadas en la capa interim.

Tabla	Granularidad	Filas iniciales	Uso previsto
siar_weather_daily.csv	Estación y fecha observada	150	Histórico agroclimático.
siar_crop_water_needs_daily.csv	Estación, cultivo y fecha	150	Baseline de necesidad neta de riego.
aemet_forecast_daily.csv	Municipio, emisión y fecha válida	7	Planificación de varios días.
aemet_forecast_hourly.csv	Municipio, emisión e instante válido	48	Decisiones de corto plazo.
quality_summary.csv	Conjunto de datos	4	Control de duplicados, cobertura y avisos.

Ejemplo de la tabla diaria SiAR:

Tabla 4.5. Ejemplo de la tabla diaria normalizada de SiAR.

Fecha	Temperatura media (°C)	Humedad media (%)	ET0 (mm/día)	Calidad
01/05/2025	19,62	75,60	4,72	PASS
02/05/2025	21,47	59,55	5,57	PASS
03/05/2025	19,93	58,28	5,27	PASS

Ejemplo de necesidades hídricas del pimiento: cuatro fechas mensuales seleccionadas; no son filas consecutivas.

Tabla 4.6. Ejemplo de la tabla normalizada de necesidades hídricas del pimiento.

Fecha	Kc	ET0 (mm)	ETc (mm)	Pe (mm)	Necesidad neta (mm)
01/05/2025	0,50	4,72	2,36	0,00	2,36
01/07/2025	0,90	6,05	5,45	0,00	5,45

Fecha	Kc	ET0 (mm)	ETc (mm)	Pe (mm)	Necesidad neta (mm)
01/08/2025	1,00	5,26	5,26	0,00	5,26
01/09/2025	0,30	4,56	1,37	0,00	1,37

Ejemplo de predicción diaria AEMET: se muestran D+0, D+1, D+2 y D+4; el horizonte D+3 se omite solo en esta muestra.

Tabla 4.7. Ejemplo de la tabla normalizada de predicción diaria de AEMET.

Fecha válida	Horizonte	Tmin (°C)	Tmax (°C)	Probabilidad máxima de lluvia
24/09/2026	D+0	21	30	0 %
25/09/2026	D+1	21	27	0 %
26/09/2026	D+2	21	31	0 %
28/09/2026	D+4	21	28	30 %

4.1.7. Volumen antes y después de la limpieza

La limpieza no elimina automáticamente las filas que contienen ausencias. Se conservan para mantener la trazabilidad y se marcan mediante controles de calidad. Por este motivo, las 150 observaciones SiAR y las 150 filas del CSV de necesidades permanecen en la capa normalizada, pero solo 148 días contienen una variable objetivo válida y pueden utilizarse en aprendizaje supervisado.

Tabla 4.8. Volumen de registros por capa antes y después de la limpieza.

Etapa	Conjunto	Entrada o salida	Filas	Variables	Filas válidas	Avisos	Duplicados
Raw	SiAR meteorológico	JSON original	150	n.a.	n.a.	n.a.	n.a.
Raw externo	Necesidades del pimiento	CSV oficial	150	6	n.a.	n.a.	n.a.

Etapa	Conjunto	Entrada o salida	Filas	Variables	Filas válidas	Avisos	Duplicados
Raw	AEMET diaria	Objeto municipal	1	n.a.	n.a.	n.a.	n.a.
Raw	AEMET horaria	Objeto municipal	1	n.a.	n.a.	n.a.	n.a.
Interim	SiAR meteorológico normalizado	CSV	150	22	148 con ET0	2	0
Interim	Necesidades hídricas normalizadas	CSV	150	15	148 con necesidad neta	2	0
Interim	Predicción AEMET diaria	CSV	7	22	7	0	0
Interim	Predicción AEMET horaria	CSV	48	22	45 sin avisos	3	0
Processed	Tabla analítica integrada	CSV	150	88	148 etiquetas	2	0

En AEMET, una fila raw representa un objeto municipal que contiene una serie anidada. La normalización lo despliega en siete fechas diarias y 48 instantes horarios; por tanto, el aumento de filas no es una duplicación. La tabla processed conserva 150 filas y ocupa aproximadamente 133 kB. Para el modelado se utilizan 148 observaciones: 125 en desarrollo y 23 en prueba final. AEMET no se une todavía al entrenamiento porque la predicción disponible corresponde a 2026 y el ciclo histórico de SiAR corresponde a 2025.

Estas cifras se regeneran mediante python -m src.analysis.build_etl_audit_4_1 y quedan registradas en docs/data_samples/etl_volume_summary_4_1.csv. De esta forma, la tabla de la memoria puede contrastarse con los archivos reales del proyecto.

4.1.8. Controles de calidad

Cada registro recibe quality_status y quality_issues. Se comprueban:

- presencia de variables críticas;

- orden lógico entre temperatura mínima, media y máxima;
- humedad entre 0 % y 100 %;
- precipitación, viento, radiación y ET0 no negativos;
- probabilidad entre 0 % y 100 %;
- unicidad de las claves lógicas;
- continuidad del calendario entre la primera y la última fecha;
- trazabilidad hasta el archivo raw.

Las 150 fechas meteorológicas y las 150 fechas de necesidades hídricas se corresponden completamente y no presentan duplicados. La diferencia máxima de ET0 entre ambas tablas es inferior a 0,005 mm y se explica por el redondeo de la web. SiAR no devuelve los días 18, 19 y 20 de julio, que quedan registrados como huecos de calendario. Además, mantiene el 21 y 22 de julio con Kc, pero sin ET0, ETc, precipitación efectiva ni necesidad neta; ambas filas quedan marcadas como aviso. En AEMET horaria se identificaron tres avisos por campos no proporcionados en los extremos del producto. Los valores ausentes no se sustituyen por cero porque cero y dato no disponible tienen significados distintos.

El resumen obtenido fue:

Tabla 4.9. Resumen de los controles de calidad por tabla.

Tabla	Filas	Duplicados	Filas con avisos	Fechas ausentes
SiAR diaria	150	0	2	3
Necesidades hídricas de pimiento	150	0	2	3
AEMET diaria	7	0	0	0
AEMET horaria	48	0	3	n.a.

4.1.9. Almacenamiento y escalabilidad

Los CSV de la capa interim facilitan la inspección inicial y el intercambio de muestras. Para una extracción nacional o un histórico extenso se propone migrar las tablas a Parquet, particionado por fuente, estación o municipio y año-mes. Parquet reduce espacio, conserva tipos y permite leer solo las columnas y particiones necesarias.

La futura base MySQL almacenará catálogos, recomendaciones y metadatos que deban consultarse transaccionalmente. Los históricos voluminosos y artefactos de modelo podrán

permanecer en almacenamiento de objetos. Esta separación evita utilizar la base transaccional como repositorio de archivos y mantiene una arquitectura compatible con ejecución local y despliegue cloud.

4.1.10. Reproducibilidad y seguridad

El proceso se reproduce mediante:

```
python -m src.data.extract_pilot
python -m src.data.extract_siar_history --start-date 2025-05-01 --end-date 2025-09-30
python -m src.data.transform_interim
python -m src.analysis.build_etl_audit_4_1
python -m src.visualization.build_etl_visual
```

Las pruebas automatizadas verifican construcción de consultas, fechas, descarga en dos pasos, ocultación de credenciales, validación de URLs, estructura de los archivos raw, normalización de códigos, cálculo de horizontes y aplanado de viento y rachas.

Las credenciales se guardan únicamente en .env, excluido de Git. El archivo .env.example documenta los nombres de las variables sin incluir valores reales.

4.1.11. Limitaciones

El ciclo completo permite validar la integración, pero un único año y una sola estación no son suficientes para entrenar un modelo generalizable. Los resultados de los apartados 4.3 y 5.3 deben leerse con esta restricción, y la ampliación a varias campañas y a otras estaciones de Almería se plantea como primera línea de mejora en el apartado 6.3. La coherencia de unidades de las variables agronómicas quedó confirmada en el apartado 5.3.1, donde el cálculo del motor reproduce la necesidad publicada por SiAR con una diferencia máxima de 0,008 mm. SiAR y AEMET representan el entorno de sus estaciones o municipios, por lo que la recomendación debe declarar esta limitación e incorporar datos locales de parcela cuando estén disponibles.

4.2. Análisis exploratorio y preparación de variables

El análisis exploratorio conecta las tablas normalizadas del apartado 4.1 con el desarrollo del modelo del apartado 4.3. Su objetivo es comprobar la cobertura y coherencia de los datos, describir el comportamiento de las variables, preparar una tabla analítica diaria y definir qué información puede utilizarse en una predicción real sin introducir fuga de información. El proceso se ha implementado de forma reproducible en src/analysis/build_eda_4_2.py, apoyándose en las transformaciones de src/features/feature_engineering.py.

4.2.1. Alcance y unidad de análisis

El piloto utiliza el cultivo de pimiento y la estación SiAR AL01 La Mojonera, en Almería, entre el 1 de mayo y el 30 de septiembre de 2025. La unidad de análisis es una combinación de fecha, estación y cultivo. Las tablas meteorológica y agronómica se unen por station_code y observed_date; el cultivo se conserva como parte de la clave analítica. El resultado contiene 150 registros y 88 columnas entre variables de origen, controles de calidad, atributos derivados, retardos y ventanas temporales.

Tabla 4.10. Cobertura y calidad del conjunto de datos del piloto.

Indicador	Resultado
Periodo esperado	01/05/2025–30/09/2025
Días naturales esperados	153
Días observados	150
Fechas ausentes	18, 19 y 20 de julio de 2025
Claves duplicadas	0
Filas PASS / WARN	148 / 2
Valores válidos de la variable objetivo	148

Los tres días ausentes se conservan como huecos de calendario. No se rellenan automáticamente porque una interpolación podría crear condiciones meteorológicas y necesidades de riego que no fueron observadas. El cálculo de retardos reindexa cada serie a frecuencia diaria antes de aplicar el desplazamiento, por lo que una observación separada por un hueco no se trata como si perteneciera al día inmediatamente anterior. Las dos filas WARN (21 y 22 de julio) carecen de ET0 y de las magnitudes derivadas. La del 21 también carece de temperatura y humedad medias, por lo que estas variables tienen 149 valores válidos en la Tabla 4.11. Los registros se conservan para trazabilidad y se excluyen del entrenamiento cuando falta la variable objetivo.

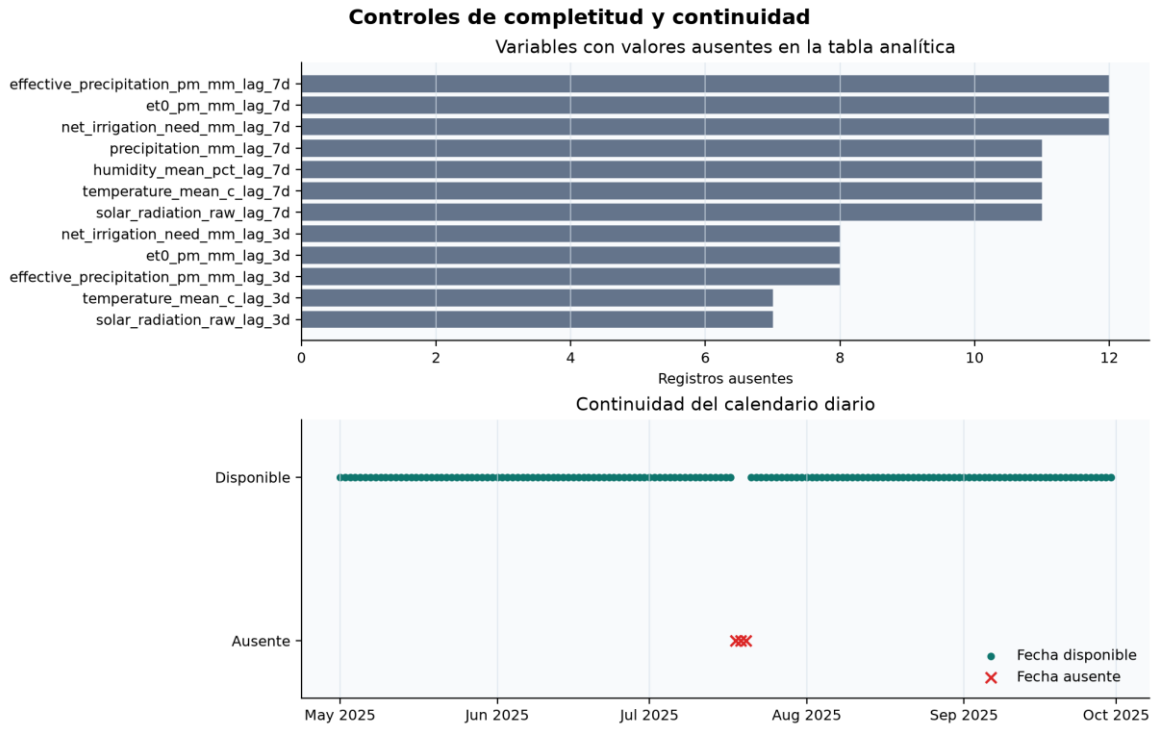


Figura 4.2. Valores ausentes y continuidad del calendario en la tabla analítica del piloto. Fuente: elaboración propia a partir de SiAR.

Los controles de plausibilidad no detectaron humedades fuera del intervalo 0–100 %, valores negativos en ET0, precipitación o necesidad neta, ni incumplimientos del orden temperatura mínima ≤ media ≤ máxima. Esto no demuestra por sí solo la validez agronómica de cada medición, pero permite descartar errores básicos de rango y signo antes del modelado.

4.2.2. Análisis descriptivo y temporal

La necesidad neta de riego diaria presenta 148 observaciones válidas, una media de 3,59 mm/día, mediana de 3,94 mm/día, desviación típica de 1,67 mm/día y valores entre 0,00 y 7,07 mm/día. La suma de la referencia SiAR durante los días disponibles asciende a 531,05 mm. La ET0 media es 5,15 mm/día y el coeficiente de cultivo medio es 0,68.

Tabla 4.11. Estadísticos descriptivos de las variables principales.

Variable	N válido	Media	Mediana	Mínimo	Máximo
Temperatura media (°C)	149	24,57	25,35	17,23	31,87
Humedad media (%)	149	59,07	60,59	29,51	83,50
ET0 (mm/día)	148	5,15	5,16	2,20	7,86
Coeficiente de cultivo Kc	150	0,68	0,70	0,30	1,00

Variable	N válido	Media	Mediana	Mínimo	Máximo
Necesidad neta (mm/día)	148	3,59	3,94	0,00	7,07

La serie temporal muestra que la necesidad neta no depende únicamente del clima. También cambia con las etapas del cultivo representadas por Kc. Durante el periodo de mayor desarrollo, Kc alcanza 1,00 y la necesidad neta se aproxima a la ET0; al final del ciclo, Kc desciende a 0,30 y la demanda calculada disminuye aunque continúe la evapotranspiración de referencia. La precipitación efectiva es escasa y concentrada, por lo que reduce la necesidad neta de forma puntual.

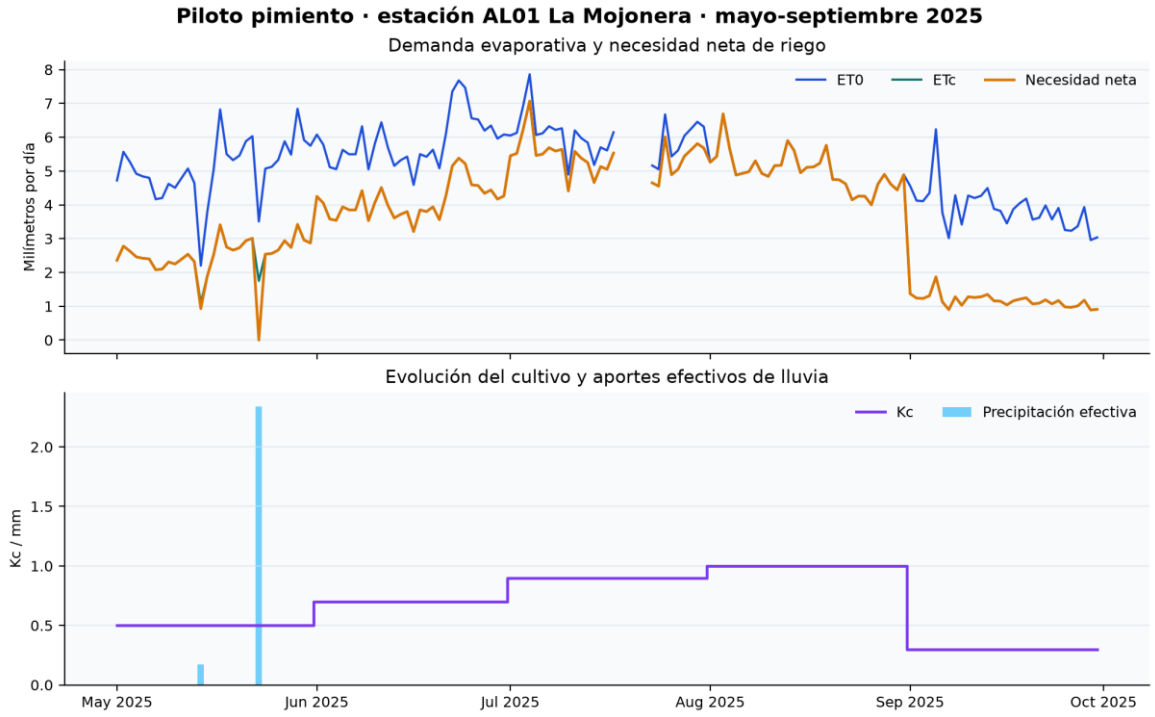


Figura 4.3. Evolución de ET0, ETc, necesidad neta, Kc y precipitación efectiva. Fuente: elaboración propia a partir de SiAR.

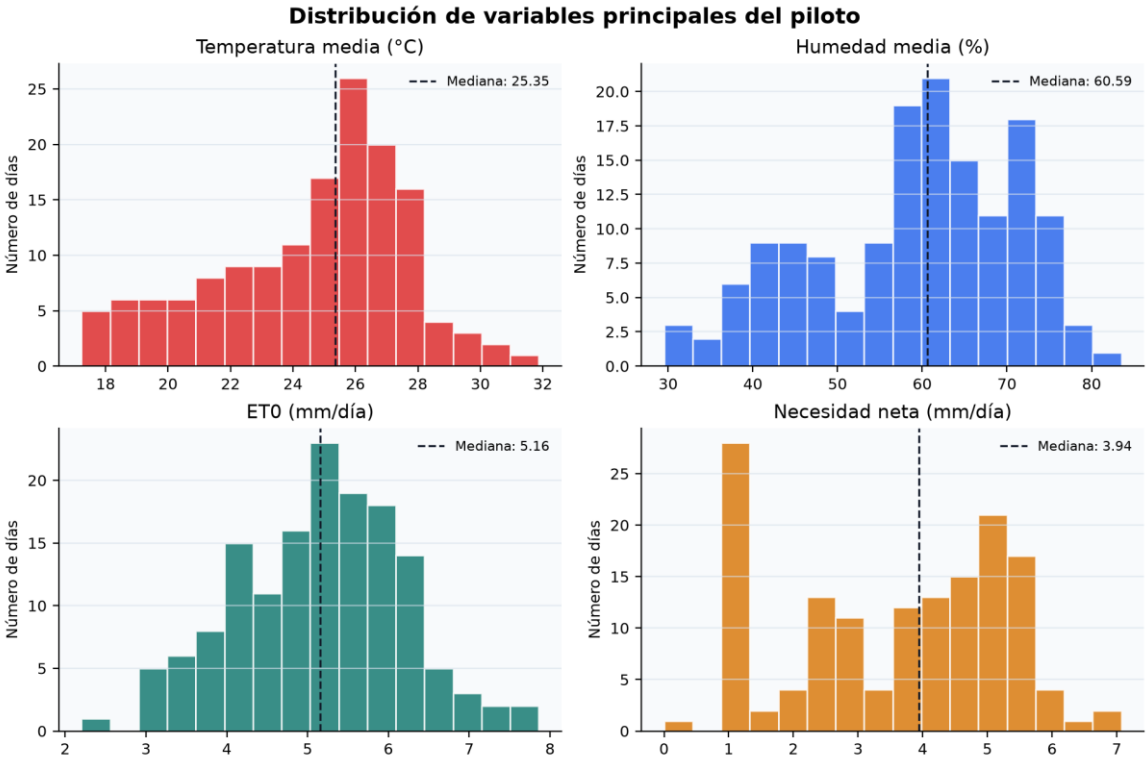


Figura 4.4. Distribución de temperatura, humedad, ET0 y necesidad neta. Fuente: elaboración propia a partir de SiAR.

4.2.3. Relaciones entre variables

El análisis de correlaciones de Pearson aporta una primera descripción lineal, sin interpretarse como causalidad. La necesidad neta se relaciona de forma positiva con Kc (0,93), ET0 (0,75), temperatura media (0,64) y radiación solar (0,52), y de forma negativa con humedad media (-0,28) y precipitación (-0,22). Las relaciones coinciden con la formulación agronómica de la referencia, ya que ETc se obtiene a partir de ET0 y Kc, y la precipitación efectiva reduce la necesidad neta.

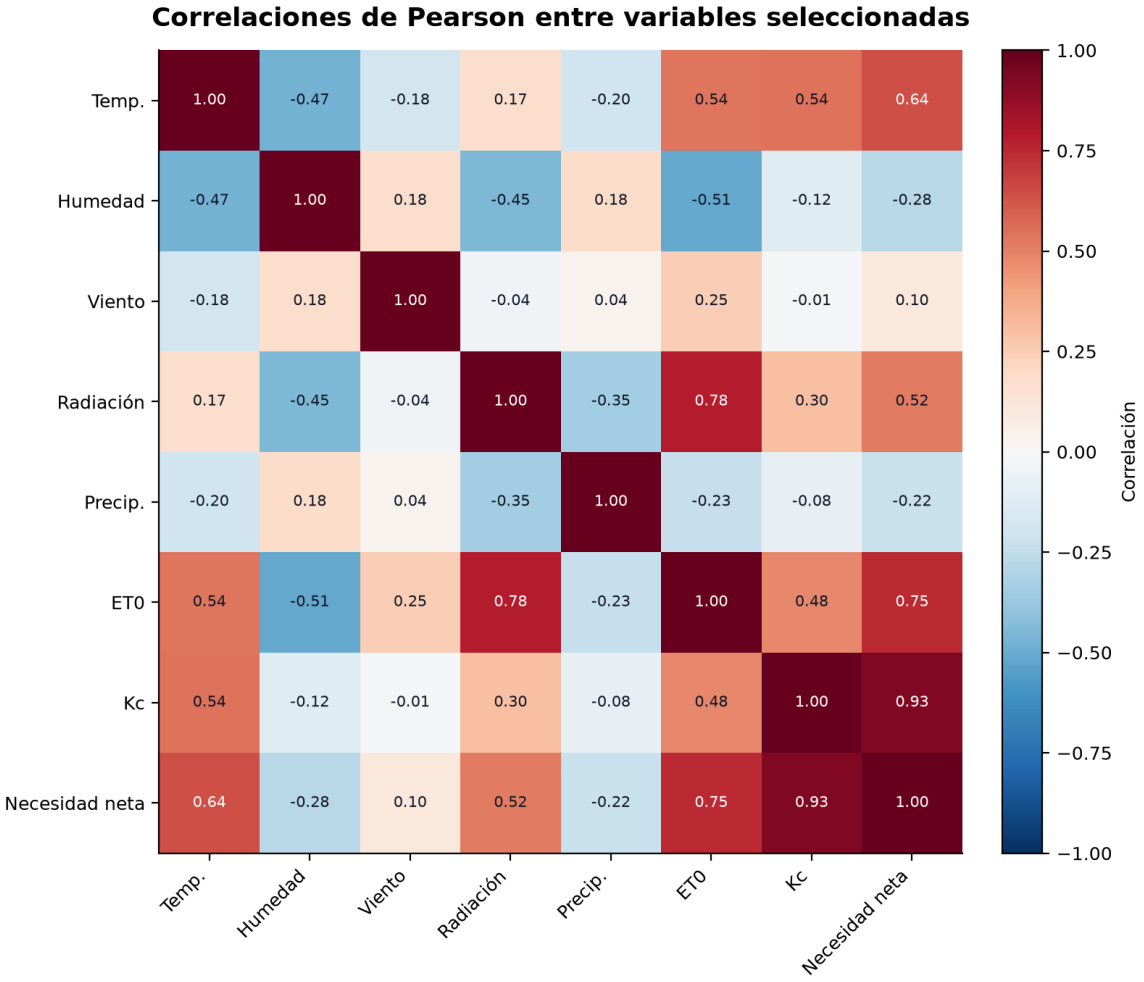


Figura 4.5. Matriz de correlaciones de Pearson para variables seleccionadas. Fuente: elaboración propia a partir de SiAR.

La elevada correlación de Kc y ET0 con el objetivo no debe presentarse como un descubrimiento independiente: forma parte de la manera en que SiAR calcula la propia etiqueta. Por esta razón, ETc y la precipitación efectiva contemporáneas se reservan para comprobaciones y no se incorporan como predictores directos de un modelo que pretenda anticipar la necesidad futura.

4.2.4. Preparación y generación de variables

La tabla final combina cuatro grupos de información:

1. Variables temporales. Año, mes, semana ISO, día del año y codificación cíclica mediante seno y coseno. Esta última representa la estacionalidad sin introducir una ruptura artificial entre el final y el inicio del año.

2. Variables agrometeorológicas derivadas. Amplitud térmica diaria, déficit de presión de vapor, ETc estimada como ET0 × Kc y necesidad neta diagnóstica como max(ETc − precipitación efectiva, 0).

3. Retardos. Valores de 1, 3 y 7 días de ET0, precipitación, temperatura, humedad, radiación y necesidad neta.

4. Ventanas temporales. Medias móviles de 3, 7 y 14 días para variables continuas, y sumas móviles para precipitación, precipitación efectiva y necesidad neta. Todas las ventanas se desplazan un día antes de calcularse, de modo que no utilizan el valor que se desea predecir.

La variable objetivo se denomina target_net_irrigation_need_mm y corresponde a la necesidad neta diaria calculada por SiAR. Se trata de una etiqueta agronómica de referencia, no del riego realmente aplicado en una explotación. En consecuencia, el modelo del apartado 4.3 medirá su capacidad para reproducir o anticipar dicha referencia. La validación en campo y los registros reales de riego quedan como una ampliación necesaria para evaluar ahorro de agua, productividad o impacto económico.

4.2.5. Disponibilidad de variables y prevención de fuga de información

Para que la evaluación sea realista se distingue entre información conocida de antemano, observaciones disponibles al cierre del día y variables que solo existen después de calcular el objetivo.

Tabla 4.12. Clasificación de variables según su disponibilidad y función en el modelo.

Grupo	Ejemplos	Uso propuesto
Conocidas de antemano	Cultivo, estación, fecha y Kc planificado	Candidatas para predicción
Meteorología observada	Temperatura, humedad, viento, radiación y ET0	Prototipo retrospectivo; para futuro exige pronóstico
Históricas desplazadas	Retardos y ventanas hasta t−1	Candidatas si están disponibles en producción
Derivadas contemporáneas	ETc, precipitación efectiva y necesidad reconstruida	Solo diagnóstico; excluir del entrenamiento
Calidad y trazabilidad	Estados, incidencias, fichero y fecha de ingesta	Auditoría; no predictores

El catálogo docs/data_samples/feature_catalog_4_2.csv documenta las 88 columnas, su tipo, disponibilidad, porcentaje de ausencias, función y riesgo de fuga. Este control sirvió para seleccionar las variables del apartado 4.3. También evita que un buen resultado aparente provenga de introducir en el modelo componentes que determinan algebraicamente la etiqueta.

La muestra AEMET disponible no se incorpora al entrenamiento: corresponde a una predicción emitida en septiembre de 2026 y no coincide temporalmente con el ciclo SiAR de 2025. Sirve como prueba de integración del sistema operacional. Para entrenar un modelo de recomendación futura será necesario obtener predicciones meteorológicas históricas emitidas antes de cada fecha objetivo o definir un escenario de prototipo retrospectivo basado exclusivamente en observaciones SiAR.

4.2.6. Estrategia de preparación para el modelado

La división de entrenamiento, validación y prueba debe respetar el orden temporal. Una partición aleatoria mezclaría días muy próximos de la misma campaña y produciría una estimación optimista del error. En este piloto se entrenó con el tramo inicial y se evaluó con fechas posteriores; cuando se amplíe el histórico, deberán reservarse campañas completas y, posteriormente, estaciones completas para medir generalización temporal y espacial.

Las imputaciones y escalados se ajustarán únicamente con el conjunto de entrenamiento. Las filas sin objetivo no pueden utilizarse para supervisar el modelo. Los retardos generan ausencias esperadas al inicio de la serie y después de huecos del calendario; dichas ausencias se tratarán mediante un Pipeline reproducible, sin reemplazarlas por cero salvo que el significado agronómico lo justifique.

El conjunto actual es suficiente para verificar el flujo técnico, crear una línea base y detectar problemas de integración. No es suficiente para afirmar que el modelo se generaliza a otras campañas, estaciones, zonas o cultivos: solo existen una estación, un cultivo, una campaña y 148 etiquetas válidas. Esta limitación condicionará la interpretación de las métricas del apartado 4.3.

4.2.7. Resultados reproducibles

La ejecución de python -m src.analysis.build_eda_4_2 genera:

- **data/processed/modeling_dataset_daily.csv:** tabla completa de modelización, excluida de Git por ser un dato generado.
- **eda_summary_4_2.json:** resumen verificable de cobertura, calidad, objetivo y correlaciones.
- **eda_variable_summary_4_2.csv:** estadísticos descriptivos de las variables principales.
- **feature_catalog_4_2.csv:** catálogo de variables y control de fuga de información.
- **modeling_dataset_sample_4_2.csv:** muestra ligera de la tabla preparada.
- **docs/images/:** cuatro figuras sobre series, distribuciones, correlaciones y calidad.

Con ello, el apartado 4.2 queda cerrado como un proceso repetible: parte de las tablas normalizadas, documenta sus limitaciones, genera variables temporales y agronómicas, distingue la disponibilidad real de cada predictor y produce una tabla preparada para la comparación de modelos del apartado 4.3.

4.3. Desarrollo y evaluación del modelo predictivo

El objetivo de esta fase es comprobar si un modelo puede anticipar la necesidad neta diaria de riego publicada por SiAR para el piloto de pimiento en la estación AL01 La Mojonera. La variable objetivo, target_net_irrigation_need_mm, es una referencia agronómica calculada y no una medición del riego aplicado ni de la respuesta real del cultivo. Por ello, el experimento demuestra la viabilidad del flujo de modelización del DSS, pero no permite afirmar todavía que se optimice el consumo de agua.

4.3.1. Conjunto de modelización y prevención de fuga de información

El entrenamiento consume directamente la tabla analítica construida en el apartado 4.2 (data/processed/modeling_dataset_daily.csv). Así se mantiene la trazabilidad entre extracción, preparación y modelización, y se evita repetir transformaciones con criterios diferentes. De los 150 días del ciclo, 148 disponen de objetivo válido y participan en el experimento.

La tabla analítica tiene 88 columnas, pero muchas son identificadores, controles de calidad, variables del propio objetivo o meteorología del día futuro no disponible al emitir. Los nueve predictores seguros son Kc, las dos componentes cíclicas del día del año, tres retardos de la necesidad y tres acumulados históricos. Se calculan por fecha de calendario, de modo que los huecos no se tratan como días consecutivos.

Se excluyen expresamente la ET0, la ETc y la precipitación efectiva del mismo día, así como las variables diagnósticas derivadas de ellas. La referencia SiAR se aproxima mediante max(ET0 × Kc − Pe, 0); incluir esos campos permitiría reconstruir el objetivo de forma algebraica y produciría métricas aparentemente buenas sin capacidad predictiva real. Los valores ausentes restantes se imputan con la mediana aprendida exclusivamente en cada periodo de entrenamiento.

4.3.2. Diseño de validación temporal

La evaluación mantiene el orden cronológico. Los últimos 23 registros, del 8 al 30 de septiembre de 2025, se reservan como prueba final y no intervienen en la selección. Las 125 observaciones anteriores forman el periodo de desarrollo. Sobre este periodo se aplica una validación temporal con tres cortes y ventana expansiva: cada modelo aprende únicamente con el pasado y se valida sobre el bloque inmediatamente posterior. Los tres cortes usan 32/31, 63/31 y 94/31 observaciones de entrenamiento/validación y representan predicciones a un día con nuevas observaciones disponibles, no una semana futura completa.

La selección de los seis enfoques se hizo por el MAE medio de los tres cortes de desarrollo antes de consultar los 23 registros de septiembre. El capítulo 5 volvió a usar esas fechas para evaluar el método ET0 reciente por Kc; por ello no deben presentarse como una segunda prueba independiente de todo el proyecto. Se fija la semilla 42 y las predicciones se limitan a un mínimo físico de 0 mm/día.

4.3.3. Enfoques comparados

Se comparan seis alternativas con distinta complejidad. Los tres enfoques iniciales se conservan y se añaden KNN, SVR y XGBoost para ampliar la evidencia antes de elegir el modelo:

1. **Persistencia:** para una predicción a un día, asigna al día t la necesidad observada en t-1. Si el retardo no está disponible, utiliza la mediana aprendida en el periodo de entrenamiento. No es un algoritmo de aprendizaje automático, sino un baseline temporal que los modelos más complejos deben superar.
2. **Regresión Ridge:** modelo lineal regularizado, precedido por imputación y estandarización. Aporta una referencia interpretable y reduce el riesgo de sobreajuste.
3. **Random Forest:** conjunto de 300 árboles, con profundidad máxima de cinco niveles y un mínimo de cuatro muestras por hoja. Representa relaciones no lineales con una configuración conservadora para el tamaño muestral.
4. **KNN Regressor:** estima cada día a partir de los siete vecinos más cercanos, ponderados por distancia. Incluye imputación y estandarización porque las distancias son sensibles a la escala de las variables.
5. **Support Vector Regression:** utiliza un kernel RBF para representar relaciones no lineales. Se configura con C=10 y epsilon=0,1, precedido por imputación y estandarización.
6. **XGBoost Regressor:** aplica *gradient boosting* sobre 250 árboles poco profundos, con tasa de aprendizaje de 0,03, submuestreo y regularización. La configuración es deliberadamente conservadora para reducir el riesgo de sobreajuste en una muestra pequeña.

No se buscan hiperparámetros sobre el tramo de prueba. Todos los modelos se comparan con configuraciones fijadas, la misma matriz de predictores y los mismos cortes temporales. La persistencia participa en el mismo procedimiento de selección, evitando desplegar un algoritmo más complejo si no aporta una mejora estable y medible.

4.3.4. Métricas de evaluación

El MAE diario es la métrica principal porque se interpreta directamente en milímetros y es menos sensible que el RMSE a episodios extremos. Se añaden el RMSE diario, el coeficiente R^2, el sesgo medio —positivo cuando se sobreestima y negativo cuando se infraestima— y el MAE de los acumulados semanales. Aquí los bloques semanales parten de la primera fecha de cada corte y suman hasta siete días de calendario, incluido un bloque final parcial; no equivalen a las semanas naturales completas del apartado 5.3.5. Esta métrica es coherente con el DSS, que debe ofrecer recomendaciones diarias y semanales. El R^2 se interpreta con cautela: el tramo final presenta una variación reducida de la necesidad neta y puede producir valores negativos aunque el error absoluto sea pequeño. Por ello no se utiliza para seleccionar el modelo.

4.3.5. Resultados de validación

Tabla 4.13. Rendimiento medio en los tres cortes de validación temporal.

Enfoque	MAE diario (media ± desv.)	RMSE diario	Sesgo diario	MAE semanal
Persistencia	**0,434 ± 0,075**	**0,644**	**0,013**	**0,926**
Ridge	0,602 ± 0,303	0,742	0,292	2,803
Random Forest	1,118 ± 0,090	1,385	-0,432	6,396
KNN	0,937 ± 0,284	1,113	-0,413	5,383
SVR	1,052 ± 0,136	1,263	-0,731	5,876
XGBoost	1,141 ± 0,340	1,378	-0,535	6,607

La persistencia obtiene el menor MAE medio. Ridge solo supera ligeramente al baseline en el tercer corte (0,356 frente a 0,408 mm/día), pero su MAE aumenta hasta 1,029 mm/día en el segundo. KNN queda en una posición intermedia, mientras que Random Forest, SVR y XGBoost no compensan su mayor complejidad. Ningún algoritmo de aprendizaje supera de forma estable a la persistencia en los tres cortes. La Figura 4.6 hace visible esta inestabilidad y justifica seleccionar el baseline antes de consultar la prueba final.

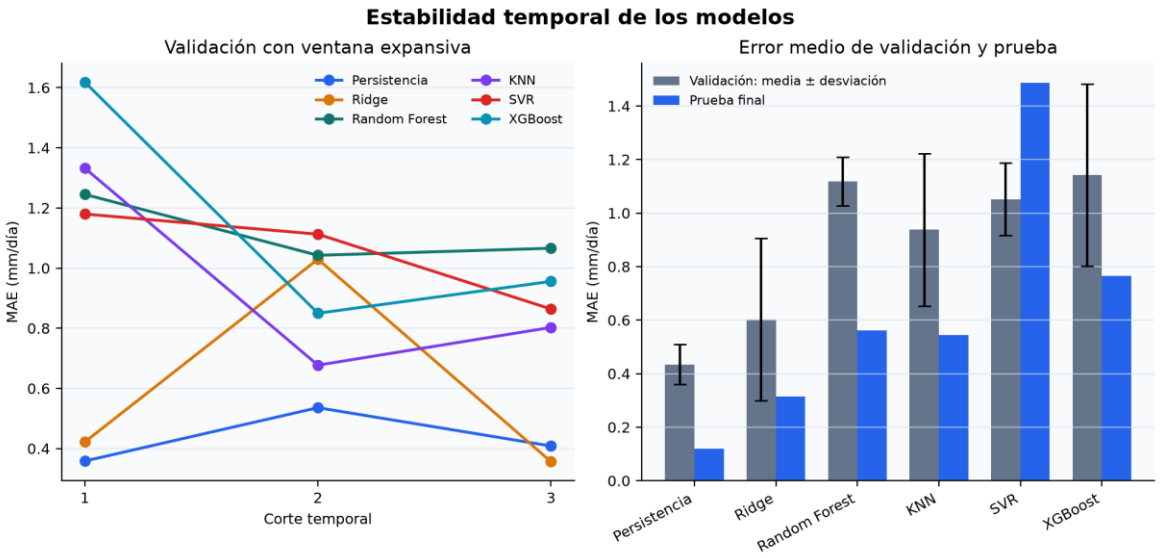


Figura 4.6. Estabilidad temporal de los modelos durante la validación y comparación con la prueba final.

4.3.6. Evaluación sobre el tramo de prueba

Tabla 4.14. Resultados sobre el periodo de prueba reservado.

Enfoque	MAE diario	RMSE diario	R^2	Sesgo diario	MAE semanal
Persistencia	**0,120**	**0,156**	-0,561	0,000	**0,172**
Ridge	0,314	0,352	-6,962	-0,310	1,784
Random Forest	0,562	0,583	-20,780	0,562	3,232
KNN	0,544	0,562	-19,211	0,544	3,128
SVR	1,486	1,503	-143,726	1,486	8,543
XGBoost	0,766	0,782	-38,145	0,766	4,402

La persistencia sigue de cerca la referencia SiAR y no presenta sesgo apreciable. Ridge conserva el segundo mejor resultado y tiende a infraestimar conforme avanza septiembre. KNN, Random Forest, SVR y XGBoost sobreestiman el tramo final. El R^2 negativo de la persistencia no contradice su MAE de 0,120 mm/día: durante la prueba la referencia se concentra en un intervalo estrecho, aproximadamente entre 0,89 y 1,35 mm/día, por lo que el denominador del R^2 es pequeño. La Figura 4.7 muestra las predicciones y el error con signo de los seis enfoques.

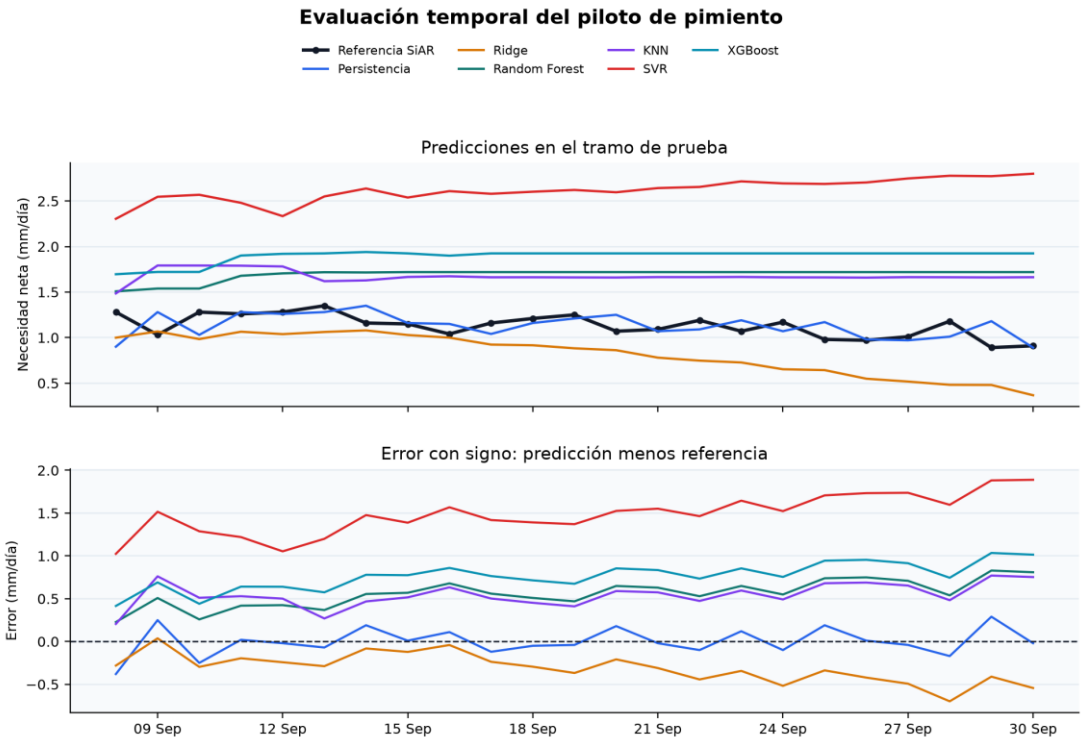


Figura 4.7. Predicciones y errores diarios de los seis enfoques en el tramo de prueba.

4.3.7. Decisión e interpretación

Con la evidencia disponible, la decisión técnica es mantener la persistencia como referencia predictiva del piloto y no desplegar todavía ninguno de los cinco algoritmos de aprendizaje. Ridge se conserva como el mejor candidato de machine learning para futuras comparaciones. Esto no significa que el aprendizaje automático carezca de utilidad, sino que la muestra actual —un único ciclo, cultivo y estación— no contiene información suficiente para demostrar una mejora estable frente a una serie muy autocorrelacionada.

El buen resultado de la persistencia es coherente con el problema evaluado. El objetivo cambia gradualmente entre días consecutivos porque el Kc y gran parte de las condiciones meteorológicas presentan continuidad. Su uso operativo es de un día vista y supone que, al emitir la recomendación, la necesidad del día anterior ya está disponible. Para predecir una semana completa sin nuevas observaciones sería necesario evaluar una estrategia recursiva diferente, en la que cada predicción alimente el día siguiente.

El resultado también evita confundir dos funciones del DSS. La fórmula SiAR sigue siendo el baseline agronómico explicable para calcular la necesidad cuando se conocen las variables meteorológicas del día. La persistencia es el baseline predictivo para anticiparla con información pasada. Un modelo futuro deberá superar ambos referentes en el contexto de uso que le corresponda.

4.3.8. Limitaciones y evolución prevista

La etiqueta reproduce una referencia calculada y no incorpora humedad del suelo, condiciones específicas de la parcela, eficiencia de la instalación, riego aplicado, drenaje, rendimiento ni estrés del cultivo. Además, la meteorología AEMET disponible no coincide temporalmente con el ciclo usado para entrenar. Por ello, las métricas no demuestran ahorro de agua ni generalización a otras parcelas.

Antes de reconsiderar el despliegue se deben incorporar varias campañas y estaciones, alinear datos meteorológicos históricos y pronosticados, y registrar riego real y sensores de parcela. Una evolución coherente consiste en estimar primero la ET0 futura con predicciones meteorológicas y, cuando existan observaciones agronómicas suficientes, aprender una corrección sobre el baseline físico. La comparación deberá repetirse por campaña y estación, manteniendo grupos temporales independientes.

4.3.9. Reproducibilidad y evidencias

El flujo se implementa en src/models/train_evaluate.py y se ejecuta con:

```
python -m src.models.train_evaluate
```

El comando genera el informe completo de validación y prueba (docs/data_samples/model_evaluation_4_3.json), las predicciones de los seis enfoques para los 23 días finales (docs/data_samples/model_predictions_4_3.csv), las Figuras 4.6 y 4.7 y el modelo serializado localmente. Este último se excluye de Git por ser un artefacto reproducible. Las pruebas automatizadas verifican el orden temporal, el tratamiento de huecos, la reutilización de variables del 4.2, la exclusión de variables con fuga, la restricción no negativa y la reproducibilidad.

5. Sistema de recomendación y resultados

5.1. Diseño del sistema de recomendación de riego

El capítulo anterior dejó dos resultados que condicionan el diseño del sistema. Por un lado, la necesidad neta publicada por SiAR puede reconstruirse a partir de la ET0, el coeficiente de cultivo y la precipitación efectiva, de modo que existe una referencia agronómica explicable para los días ya cerrados. Por otro, ninguno de los cinco algoritmos de aprendizaje automático evaluados en el apartado 4.3 superó de forma estable a la persistencia cuando se trata de anticipar el día siguiente. El motor de recomendación se ha construido a partir de ambas constataciones. Su función consiste en transformar la información disponible en una dosis de riego diaria y en un total para el horizonte solicitado, dejando constancia del origen de cada cifra y de las situaciones en las que la propuesta merece menos confianza.

El sistema se mantiene dentro del alcance definido en el apartado 1.3. No acciona válvulas ni programadores y no pretende sustituir el criterio del técnico o del agricultor. Tampoco estima el riego óptimo medido en parcela, porque no se dispone de humedad del suelo, riego aplicado ni respuesta productiva. Lo que ofrece es una referencia hídrica razonada, acompañada de las reglas que la han modificado y de las advertencias que deben revisarse antes de regar, en línea con el planteamiento híbrido descrito en el apartado 2.3 (Navarro-Hellín et al., 2016; Zhai et al., 2020).

5.1.1. Requisitos de partida

Los requisitos se derivaron de los objetivos del capítulo 1 y de las limitaciones detectadas durante el procesamiento de los datos. El usuario debe poder indicar la fecha en la que solicita la recomendación, el número de días que desea planificar, el sistema de riego o su eficiencia, la superficie de la parcela y, si existe, una dotación semanal máxima. Con esos parámetros el sistema tiene que devolver, para cada día, la necesidad neta en milímetros, la dosis bruta ajustada por eficiencia, el volumen cuando se conoce la superficie, un nivel de confianza, las advertencias pertinentes y una explicación en lenguaje llano.

A estos requisitos funcionales se añadieron tres condiciones de diseño. La primera es temporal: una recomendación emitida en una fecha solo puede utilizar información disponible antes de esa fecha, igual que se exigió a los modelos del capítulo 4. La segunda es de trazabilidad: cada resultado debe poder relacionarse con el método que lo produjo, las reglas aplicadas, el archivo de origen y el último dato observado. La tercera es de prudencia: ante datos ausentes, desactualizados o fuera del intervalo conocido, el sistema debe avisar o abstenerse antes que ofrecer una cifra aparentemente precisa. La literatura sobre adopción de herramientas agrícolas insiste en que la confianza del usuario depende de que entienda por qué se le propone una

actuación (Rose et al., 2016), y por esa razón la explicación forma parte de la salida y no de la documentación.

5.1.2. Arquitectura del motor

La Figura 5.1 resume el recorrido de una consulta. Las entradas del usuario y los datos de la fuente alimentan un módulo de estimación diaria; su resultado pasa por un conjunto de reglas numeradas y, finalmente, se genera una salida diaria y un resumen del horizonte. La lógica se encuentra en src/dss, separada de los clientes de las APIs y de los módulos de modelado, de forma que puede reutilizarse desde la línea de comandos, desde la interfaz del apartado 5.2 o desde los scripts de validación del apartado 5.3.

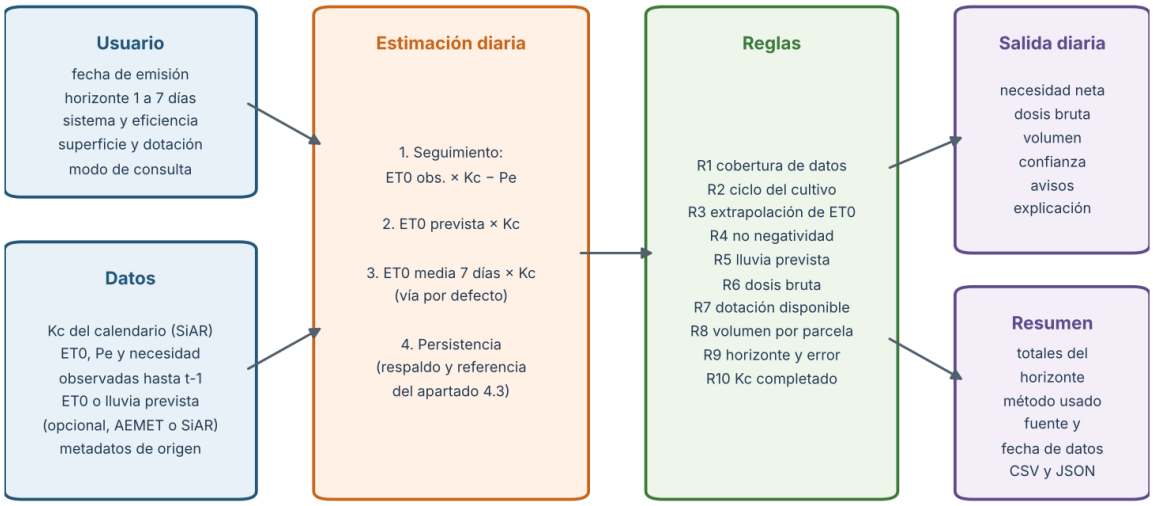


Figura 5.1. Flujo de una consulta en el motor de recomendación.

El caso analizado se describe mediante un objeto de configuración que reúne cultivo, sistema productivo, estación y archivo de origen. Para el piloto, ese objeto apunta al CSV oficial de necesidades de pimiento de la estación AL01 La Mojonera. Cambiar de cultivo o de estación consiste en declarar un caso nuevo con su propio archivo, sin modificar el motor. Al cargar la fuente, el sistema reconstruye el calendario diario completo: las tres fechas que SiAR no devolvió en julio se conservan como filas sin dato y no se interpretan como necesidad nula. Como el coeficiente de cultivo procede del calendario del cultivo y se conoce de antemano, en esas fechas se toma el último valor publicado y se marca la imputación.

5.1.3. Estimación de la necesidad neta

El motor distingue dos modos de consulta. En el modo de seguimiento se analizan días ya cerrados y se aplica la expresión agronómica con las variables observadas:

```
necesidad neta = max(ET0 × Kc − Pe, 0)
```

Este modo sirve para revisar a posteriori lo que debería haberse aplicado y para comparar la planificación con la referencia. En el modo de planificación, que es el uso operativo, la ET0 y la precipitación efectiva del día que se quiere regar todavía no se conocen. Para ese caso se establecieron tres vías con un orden de preferencia fijo.

La vía preferente utiliza una ET0 prevista solo cuando se proporciona como entrada explícita. El prototipo no descarga ni calcula automáticamente ese pronóstico; los productos de SiAR y una estimación derivada de AEMET son posibilidades futuras pendientes de evaluación. La necesidad se obtiene multiplicando esa ET0 por el Kc del día. La segunda vía, que es la que se emplea por defecto en el piloto porque no se dispone de un histórico de predicciones alineado con la campaña, sustituye la ET0 futura por la media de la ET0 observada en los siete días anteriores y la combina con el Kc del día objetivo. La tercera vía es la persistencia del apartado 4.3: se repite la última necesidad neta conocida. Solo se recurre a ella cuando no hay ninguna ET0 reciente, y en todos los casos su valor se guarda junto a la recomendación como referencia de comparación.

La segunda vía merece una justificación, porque no figuraba entre los enfoques comparados en el capítulo 4. La necesidad neta del piloto depende casi por completo de dos factores, la demanda evaporativa y el coeficiente de cultivo. El primero cambia de forma gradual entre días consecutivos; el segundo cambia de golpe al pasar de una fase a otra y, sin embargo, se conoce con antelación. La persistencia trata ambos factores como si fueran igual de inerciales y, por eso, arrastra durante días el valor de la fase anterior cuando el Kc salta de 0,70 a 0,90 el 1 de julio o de 1,00 a 0,30 el 1 de septiembre. Separar los dos componentes permite aprovechar la continuidad de la ET0 sin renunciar a lo que ya se sabe del calendario. La elección de la ventana de siete días y la comparación con la persistencia en cada horizonte se presentan en el apartado 5.3; aquí basta señalar que la ventana se fijó con el periodo de desarrollo y que el tramo de prueba reservado en el capítulo 4 no intervino en esa decisión.

La lluvia prevista no se descuenta de forma automática. La precipitación efectiva depende de la intensidad, del estado del suelo y de las pérdidas por escorrentía o percolación, y solo puede valorarse con cierta fiabilidad una vez ha llovido (Allen et al., 1998). En un clima como el de la costa de Almería, donde la precipitación efectiva acumulada de toda la campaña fue de 2,51 mm, restar una lluvia pronosticada que finalmente no llega supondría dejar el cultivo sin agua en pleno verano. El sistema opta por mantener la dosis y avisar de que conviene aplazar el riego y recalcular cuando se conozca la precipitación real.

5.1.4. Reglas de decisión

Sobre la estimación se aplica un conjunto de diez reglas, numeradas para que aparezcan en la salida con la misma denominación que en esta memoria. La Tabla 5.1 recoge su finalidad y su efecto.

Tabla 5.1. Reglas aplicadas por el motor de recomendación.

Regla	Finalidad	Efecto sobre la recomendación
R1 Cobertura de datos	Comprobar que existen observaciones recientes suficientes	Cambia de vía de estimación y añade un aviso cuando faltan datos
R2 Ciclo del cultivo	Evitar recomendaciones fuera del calendario publicado	No se emite recomendación
R3 Extrapolación	Detectar una ET0 alejada más de un 10 % del intervalo observado	Aviso de extrapolación y confianza baja
R4 No negatividad	Impedir dosis negativas cuando la lluvia supera la ETc	La necesidad se fija en 0 mm
R5 Lluvia prevista	Señalar episodios de lluvia de al menos 5 mm o probabilidad del 60 %	Aviso de aplazamiento sin descontar la lluvia
R6 Dosis bruta	Incorporar las pérdidas del sistema de aplicación	Dosis bruta = necesidad neta / eficiencia
R7 Dotación disponible	Respetar un límite semanal de agua	Reducción proporcional y aviso de déficit
R8 Volumen	Expresar la dosis por parcela	1 mm sobre 1 ha equivale a 10 m3
R9 Horizonte	Informar de que el error crece con la anticipación	Se indica el error medio esperado para ese día
R10 Kc completado	Dejar constancia de fechas no devueltas por la fuente	Aviso de imputación del Kc

La regla R6 incorpora la diferencia entre lo que necesita el cultivo y lo que hay que aplicar. Las eficiencias por defecto son las orientativas de la FAO para riego de superficie, aspersión y goteo, del 60 %, 75 % y 90 % respectivamente (Brouwer et al., 1989). El usuario puede sustituirlas por la eficiencia medida en su instalación, que es preferible porque la eficiencia real depende del diseño, del mantenimiento y de la uniformidad de cada sistema (Burt et al., 1997). El valor admitido se limita al intervalo entre 0,30 y 1,00 para evitar errores de introducción.

La regla R7 es la forma en la que el prototipo incorpora una restricción de disponibilidad hídrica. El anteproyecto contemplaba utilizar el Boletín Hidrológico del MITECO, pero sus datos se publican a escala de embalse y de cuenca, con frecuencia semanal y carácter provisional (MITECO, s. f.), lo

que no permite deducir de forma directa cuánta agua corresponde a una parcela. Se ha preferido que la restricción la introduzca el usuario como dotación semanal, que es el dato que realmente recibe de su comunidad de regantes. Cuando la dosis planificada supera esa dotación, el sistema la reduce de forma proporcional y lo indica. Esta reducción es una simplificación consciente: el riego deficitario bien diseñado concentra el déficit en las fases menos sensibles del cultivo (Fereres & Soriano, 2007), y por eso el aviso invita a revisar qué días conviene recortar en lugar de presentar el reparto como óptimo.

Las reglas R1, R2, R3 y R9 traducen a la práctica la exigencia, recogida en el apartado 2.3, de que la incertidumbre forme parte de la salida. A partir de ellas se asigna a cada día un nivel de confianza. Es alta cuando se trata de un día cerrado calculado con datos observados; media en los tres primeros días de una planificación sin incidencias; y baja a partir del cuarto día o cuando existe cualquier aviso, incluido el de datos con más de dos días de antigüedad. El cuarto día es un umbral prudencial de interfaz, no una probabilidad calibrada. Los MAE por horizonte del apartado 5.3 describen este piloto y no son intervalos de predicción individuales.

5.1.5. Estructura de la salida

Cada consulta genera una tabla diaria con dieciocho campos y un resumen del horizonte. La tabla incluye la fecha, el día del horizonte, el Kc, la ET0 utilizada y su origen, la necesidad neta, el método, la persistencia como referencia, la dosis bruta, el factor de dotación, el volumen, la confianza, las reglas aplicadas, los avisos, la explicación, la fecha del último dato observado y el archivo de origen. El resumen agrega los totales, el método principal, la eficiencia aplicada y el número de días con avisos. La cabecera conserva la versión del motor, los parámetros de la consulta, la URL de la fuente y la fecha de descarga. Todo ello se exporta en CSV y JSON, lo que permite archivar las recomendaciones emitidas y compararlas más adelante con lo que realmente se regó.

La explicación se redacta a partir de los mismos valores que aparecen en la tabla. Para el 1 de julio de 2025, por ejemplo, la salida indica que la necesidad neta estimada es de 6,2 mm a partir de una ET0 media reciente de 6,84 mm y un Kc de 0,90, y que con una eficiencia del 90 % la dosis bruta propuesta es de 6,8 mm, unos 103 m3 para una parcela de 1,5 ha. La frase no añade información que no esté en los datos, pero permite que el usuario compruebe el razonamiento sin interpretar una tabla de dieciocho columnas.

5.1.6. Decisiones descartadas

Durante el diseño se valoraron otras alternativas que finalmente no se incorporaron. La primera fue utilizar como motor el modelo Ridge, segundo clasificado en el apartado 4.3. Se descartó porque no superó de forma estable a la persistencia y porque su comportamiento ante un cambio de fase del cultivo resulta menos transparente que una multiplicación por el Kc. La segunda fue

estimar la ET0 futura con la ecuación de Hargreaves a partir de las temperaturas previstas por AEMET. Es una opción contemplada en FAO-56 para cuando faltan variables (Allen et al., 1998), pero no se dispone de un histórico de predicciones de la campaña de 2025 con el que calibrarla, y presentar una vía no evaluada como parte del sistema habría contradicho el criterio seguido en el resto del trabajo. El motor admite una ET0 prevista como entrada para que esa vía pueda incorporarse cuando exista la evidencia. La tercera alternativa fue un balance hídrico del suelo con agotamiento admisible, que permitiría decidir no solo cuánto sino cuándo regar. Requiere capacidad de retención, profundidad radicular y riegos previos de la parcela, datos que el piloto no tiene, y se plantea como evolución en el capítulo 6.

5.2. Aplicación y visualización de resultados

El motor descrito en el apartado anterior solo resulta útil si una persona puede consultarlo sin abrir el código. Para ello se han preparado dos formas de acceso que comparten exactamente la misma lógica: una ejecución por línea de comandos, pensada para automatizar consultas y archivar resultados, y una aplicación web ligera, pensada para la demostración y para el usuario que quiere explorar escenarios. Ninguna de las dos realiza cálculos propios; ambas llaman a la función de recomendación de src/dss/engine.py, de modo que lo que se ve en pantalla coincide con lo que se valida en el apartado 5.3.

5.2.1. Elección de la tecnología de presentación

El anteproyecto contemplaba un cuadro de mando en Power BI o Tableau. Se mantuvo esa opción hasta disponer de un motor funcional, y en ese momento se comprobó que la herramienta debía cumplir dos condiciones que un cuadro de mando convencional resuelve con dificultad. La primera es interactiva: cambiar la fecha de emisión, el horizonte o la eficiencia tiene que volver a ejecutar el motor, no solo filtrar una tabla ya calculada. La segunda es de reproducibilidad: cualquier miembro del tribunal o del equipo debería poder lanzar la aplicación desde el repositorio con las mismas dependencias que el resto del proyecto.

Por esas razones se optó por Streamlit, una librería de Python que construye la interfaz a partir de un único script y vuelve a ejecutarlo cada vez que el usuario modifica un control (Streamlit, 2024). La aplicación se encuentra en src/dss/app_streamlit.py y se arranca desde la raíz del repositorio con streamlit run src/dss/app_streamlit.py. Power BI y Tableau quedan como alternativa para un uso agregado, por ejemplo para una cooperativa que quiera comparar parcelas a partir de las recomendaciones archivadas en CSV, pero no se presentan como implementados porque no existe un archivo funcional en el repositorio que lo demuestre.

5.2.2. Organización de la interfaz

La pantalla se divide en un panel lateral de entrada y un área principal de resultados. El panel lateral agrupa los controles en tres bloques. En el primero se muestran el cultivo y la estación del

caso analizado; están bloqueados porque el piloto valida una sola combinación, aunque el texto recuerda que el motor admite otras fuentes con el mismo formato. El segundo bloque recoge la consulta: el modo de planificación o seguimiento, la fecha de emisión y el horizonte de uno a siete días. El tercero describe la parcela: el sistema de riego, la eficiencia, que se rellena con el valor orientativo del sistema pero puede modificarse, la superficie y, de manera opcional, una dotación semanal. Una casilla final permite superponer la referencia SiAR calculada a posteriori, algo que solo tiene sentido en una demostración retrospectiva como la de este trabajo.

El área principal sigue el orden en el que un técnico suele leer una recomendación. Arriba aparecen cuatro indicadores: la necesidad neta del horizonte, la dosis bruta propuesta, el volumen estimado y el número de días con recomendación. Debajo se sitúa un gráfico de barras con la dosis bruta de cada día y la necesidad neta superpuesta, acompañado de un bloque titulado Fundamento que indica el método principal, la eficiencia aplicada, la fuente con su fecha de descarga y el último dato observado. Si existe algún aviso general, como datos desactualizados o una dotación insuficiente, se muestra en un recuadro destacado encima de los indicadores. La parte inferior contiene la tabla diaria con la confianza y los avisos, un desplegable con la explicación y las reglas aplicadas a cada día, y un botón para descargar la recomendación en CSV.

Las cifras de resultados se presentan con coma decimal y las fechas en formato día, mes y año. Puede parecer un detalle menor, pero la aplicación está dirigida a usuarios españoles y una tabla con puntos decimales obliga a una lectura más lenta y propicia errores al trasladar los valores a un programador de riego.

5.2.3. Ejemplo de uso en un cambio de fase del cultivo

Para ilustrar el funcionamiento se ha elegido una situación exigente: una planificación emitida el 28 de junio de 2025 con un horizonte de siete días, que atraviesa el paso del Kc de 0,70 a 0,90 el 1 de julio. Se considera riego por goteo con eficiencia del 90 % y una parcela de 1,5 ha. La Figura 5.2 reproduce la pantalla obtenida con la referencia SiAR superpuesta.



Fecha	Kc	ET0 usada (mm)	Necesidad neta (mm)	Dosis bruta (mm)	Volumen (m³)	Confianza	Avisos
28/06/2025	0,70	6,84	4,79	5,32	80	media	
29/06/2025	0,70	6,84	4,79	5,32	80	media	
30/06/2025	0,70	6,84	4,79	5,32	80	media	
01/07/2025	0,90	6,84	6,15	6,84	103	baja	
02/07/2025	0,90	6,84	6,15	6,84	103	baja	
03/07/2025	0,90	6,84	6,15	6,84	103	baja	
04/07/2025	0,90	6,84	6,15	6,84	103	baja	

Figura 5.2. Interfaz del DSS para una planificación emitida el 28 de junio de 2025, con la referencia SiAR superpuesta.

Con la información disponible hasta el 27 de junio, la ET0 media de los siete días anteriores es de 6,84 mm. Multiplicada por el Kc de cada día, da lugar a una necesidad neta de 4,79 mm para los tres últimos días de junio y de 6,15 mm a partir del 1 de julio. La Tabla 5.2 compara esa planificación con la referencia que SiAR publicó después y con lo que habría propuesto la persistencia.

Tabla 5.2. Planificación emitida el 28 de junio de 2025 frente a la referencia SiAR.

Fecha	Kc	Necesidad DSS (mm)	Persistencia (mm)	Referencia SiAR (mm)	Dosis bruta (mm)	Volumen (m3)	Confianza
28/06/2025	0,70	4,79	4,34	4,44	5,32	80	media
29/06/2025	0,70	4,79	4,34	4,17	5,32	80	media
30/06/2025	0,70	4,79	4,34	4,26	5,32	80	media
01/07/2025	0,90	6,15	4,34	5,45	6,84	103	baja
02/07/2025	0,90	6,15	4,34	5,52	6,84	103	baja
03/07/2025	0,90	6,15	4,34	6,24	6,84	103	baja
04/07/2025	0,90	6,15	4,34	7,07	6,84	103	baja
Total		**38,96**	**30,38**	**37,15**	**43,29**	**649**	

En el conjunto de la semana, el sistema planifica 38,96 mm netos frente a los 37,15 mm de la referencia, una diferencia de 1,81 mm o del 4,9 %. La persistencia habría propuesto 30,38 mm, es decir, 6,77 mm menos de lo que finalmente necesitó el cultivo, porque mantiene durante toda la semana el valor de junio. El ejemplo muestra el motivo por el que se separaron la ET0 y el Kc en el diseño: la subida de la demanda al cambiar de fase se anticipa desde el primer día, aunque la ET0 se suponga constante.

El ejemplo también deja ver las limitaciones. Los días 28 a 30 de junio el sistema sobrestima, porque la semana anterior tuvo una demanda evaporativa mayor que la siguiente, y el 3 y el 4 de julio infraestima por la razón contraria. Una media de siete días no puede anticipar un cambio de tiempo; para ello haría falta una ET0 prevista. La interfaz lo refleja asignando confianza media a los tres primeros días y baja a los cuatro siguientes, e indicando en las reglas el error medio esperado para cada día del horizonte.

5.2.4. Uso desde la línea de comandos

La misma consulta puede lanzarse sin interfaz, lo que resulta útil para programar una recomendación diaria o para integrarla en otro sistema:

```
python -m src.dss.recommend --fecha 2025-06-28 --horizonte 7 --superficie 1.5
```

El comando escribe en la consola la explicación de cada día y los totales, y guarda la tabla diaria y el resumen en results/reports en formato CSV y JSON. Los argumentos opcionales permiten indicar otro sistema de riego, una eficiencia propia, una dotación semanal, el modo de seguimiento o un archivo con ET0 o lluvia prevista. El ejemplo de la Tabla 5.2 se conserva también como muestra versionada en docs/data_samples/dss_recommendation_example_5_2.csv.

5.2.5. Visualización de la campaña

Además de la consulta puntual, se han generado dos figuras que resumen el comportamiento del sistema a lo largo de toda la campaña y que se analizan en el apartado 5.3. La primera simula que el agricultor consulta el sistema cada mañana con la información del día anterior y compara cada recomendación con la referencia SiAR. La segunda agrega los resultados por semanas naturales, que es la escala en la que suelen planificarse los turnos de riego y las dotaciones. Ambas se generan con el mismo código que valida el sistema, de manera que cualquier cambio en el motor se refleja automáticamente en las figuras de la memoria.

5.2.6. Limitaciones de la aplicación

La aplicación es un prototipo de demostración. No dispone de usuarios ni de control de acceso, no guarda un histórico de consultas por parcela y lee la fuente desde un archivo local en lugar de una base de datos. Tampoco descarga por sí misma la predicción de AEMET; la vía de ET0 prevista está implementada en el motor y se ha probado con datos de ejemplo, pero la interfaz trabaja con la vía por defecto. Estas carencias no impiden demostrar el funcionamiento del sistema, aunque sí condicionan su uso real. Por último, la interfaz no se ha evaluado con agricultores ni técnicos. La literatura señala que la facilidad de uso y la relevancia percibida son determinantes para que una herramienta de este tipo se adopte (Rose et al., 2016), por lo que esa evaluación con usuarios se considera un paso necesario antes de cualquier despliegue.

5.3. Validación, resultados y análisis crítico

La validación del sistema no puede limitarse a repetir las métricas del capítulo 4. Allí se evaluaba si un modelo anticipaba bien una variable; aquí interesa saber si el conjunto formado por la estimación, las reglas y la salida produce recomendaciones correctas, coherentes y seguras en las condiciones en las que se utilizaría. Siguiendo las dimensiones planteadas en el apartado 2.3, la evaluación se ha organizado en cuatro niveles: la fidelidad de la vía agronómica, el error de la planificación frente a la referencia, el comportamiento ante situaciones anómalas y el rendimiento operativo. Todas las cifras proceden de src/analysis/build_validation_5_3.py, que las regenera a partir del CSV oficial del piloto.

Conviene precisar desde el principio qué significa validar en este contexto. La referencia utilizada es la necesidad neta calculada por SiAR, no el riego aplicado por un agricultor ni la respuesta del cultivo. Tampoco se ha contado con técnicos o regantes que revisaran las recomendaciones. Lo

que se presenta es, por tanto, una validación técnica del prototipo con escenarios documentados. Demostrar un ahorro de agua o una mejora productiva exigiría un ensayo de campo con un diseño distinto, algo que queda fuera del alcance declarado en el apartado 1.3.

5.3.1. Fidelidad de la vía agronómica

El primer control consistió en comprobar que el modo de seguimiento reproduce la referencia publicada. En los 148 días con ET0 observada, la diferencia máxima entre la necesidad calculada por el motor y la publicada por SiAR fue de 0,008 mm, atribuible al redondeo a dos decimales de la fuente. Este resultado confirma que el sistema interpreta correctamente las columnas del CSV y que la expresión agronómica es la misma que utiliza SiAR.

La comprobación reveló además un matiz del total oficial. El metadato de la descarga indica una necesidad neta de 530,47 mm para la campaña, mientras que la suma de las necesidades diarias es de 531,05 mm. La diferencia procede del 23 de mayo, el único día en que la lluvia efectiva (2,34 mm) superó a la ETc (1,75 mm). SiAR obtiene el total como suma de la ETc menos suma de la lluvia efectiva y deja que ese excedente de 0,58 mm compense necesidades de otros días; el motor, en cambio, fija la necesidad de ese día en cero y no traslada el excedente. Para un sistema que no modela el almacenamiento del suelo, el segundo criterio es el más prudente, pero la discrepancia se documenta para que nadie la confunda con un error de cálculo.

5.3.2. Selección de la ventana de ET0

La vía por defecto del sistema promedia la ET0 de los días anteriores. Antes de fijar la longitud de esa ventana se evaluaron cinco alternativas, de uno a catorce días, simulando emisiones diarias con horizontes de uno a siete días. Se reutilizó el tramo del 8 al 30 de septiembre para la evaluación, aunque la ventana se seleccionó únicamente con el periodo de desarrollo. Estas fechas ya habían sido consultadas en el capítulo 4 y no constituyen una segunda prueba independiente. Como criterio se fijó, antes de calcular los resultados, elegir la ventana más corta cuyo error no superase al mínimo en más de un 1 %, porque una ventana corta reacciona antes ante un cambio de tiempo.

Tabla 5.3. MAE medio de los horizontes 1 a 7 según la ventana de ET0 (mm/día).

Ventana	Desarrollo	Prueba
1 día	0,517	0,127
3 días	0,494	0,110
5 días	0,484	0,101

Ventana	Desarrollo	Prueba
7 días	**0,471**	**0,101**
14 días	0,469	0,124

Las ventanas de siete y catorce días son prácticamente equivalentes en desarrollo, con una diferencia de 0,002 mm, y el criterio selecciona la de siete. En la prueba esa elección resulta favorable, aunque no se utilizó para decidir. La tabla muestra también que las ventanas de uno y tres días son claramente peores: la ET0 de un día aislado incorpora demasiado ruido para representar la demanda de los días siguientes.

5.3.3. Error de la recomendación a un día

El uso principal del sistema es la consulta diaria con la información del día anterior. Para evaluarlo se simuló una campaña completa en la que el sistema emite una recomendación cada mañana, del 2 de mayo al 30 de septiembre, y se comparó cada una con la referencia SiAR del mismo día. Se emitieron 152 recomendaciones, de las cuales 147 pudieron contrastarse; las cinco restantes corresponden a fechas sin referencia publicada.

Tabla 5.4. Error de la recomendación a un día frente a la referencia SiAR.

Periodo	Enfoque	Días	MAE (mm)	RMSE (mm)	Sesgo (mm)
Desarrollo	DSS (ET0 reciente × Kc)	124	**0,417**	**0,583**	0,044
Desarrollo	Persistencia	124	0,449	0,710	0,012
Prueba	DSS (ET0 reciente × Kc)	23	**0,090**	**0,113**	0,047
Prueba	Persistencia	23	0,120	0,156	0,000

Los 124 días comparables de desarrollo son uno menos que las 125 etiquetas del capítulo 4: la primera emisión se realiza el 2 de mayo y necesita historia previa. El sistema reduce el MAE respecto a la persistencia en un 7 % en desarrollo y en un 25 % en la prueba. La reducción es mayor en el RMSE, un 18 % en desarrollo, lo que indica que la mejora se concentra en los errores grandes. La Figura 5.3 ayuda a entenderlo. Los mayores errores de la persistencia se producen el primer día de cada fase, cuando repite el valor de la fase anterior; el 1 de septiembre, con el paso del Kc de 1,00 a 0,30, se desvía 3,52 mm, mientras que el sistema lo hace en 0,01 mm. El otro

episodio destacado es la lluvia del 23 de mayo, que ninguna de las dos vías puede anticipar sin una predicción de precipitación y que la persistencia arrastra además al día siguiente. El MAE de la persistencia en la prueba, 0,120 mm, coincide con el obtenido en el apartado 4.3, lo que confirma que ambos experimentos parten de la misma referencia. En desarrollo los valores no son directamente comparables con los de la Tabla 4.13, porque aquí se evalúan todas las emisiones del periodo y no tres cortes de validación.

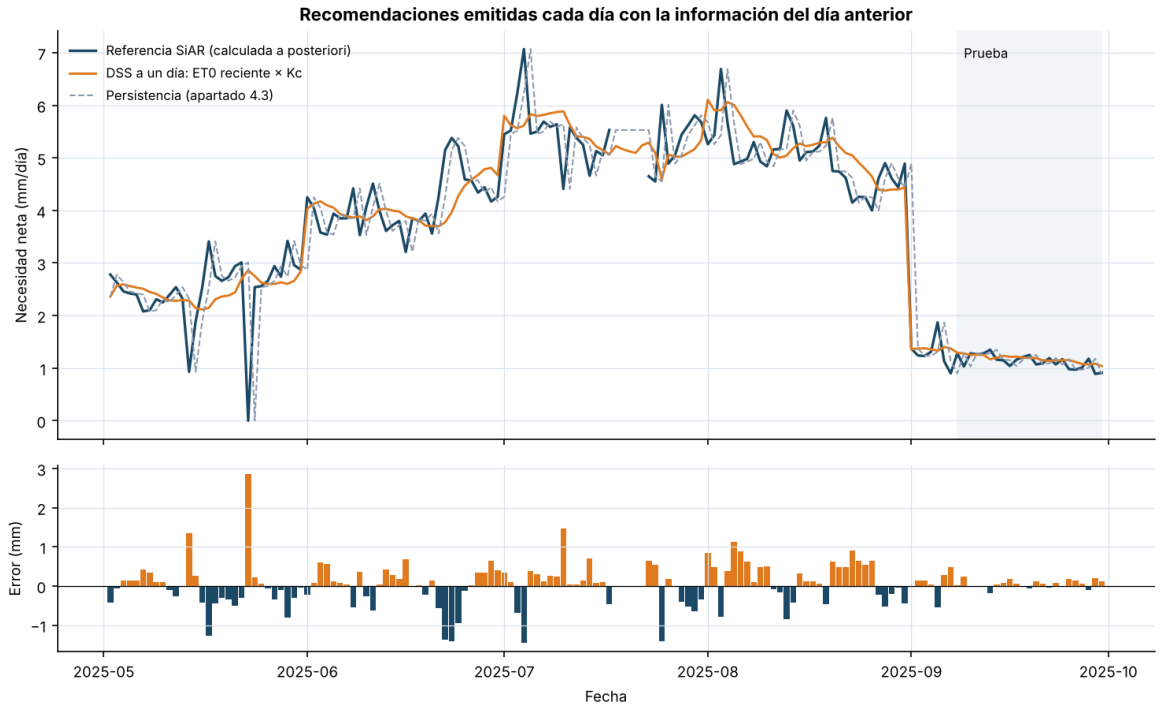


Figura 5.3. Recomendaciones emitidas cada día con la información del día anterior y error frente a la referencia SiAR.

El sesgo del sistema es ligeramente positivo, de 0,04 a 0,05 mm al día. Tiende por tanto a recomendar algo más de agua que la referencia, sobre todo en septiembre, cuando la ET0 desciende de forma sostenida y la media de los siete días anteriores queda siempre por encima del valor del día. En una herramienta de apoyo al riego un sesgo pequeño y positivo es preferible a uno negativo, porque el déficit hídrico tiene consecuencias más difíciles de revertir que un ligero exceso. Aun así, a lo largo de la campaña ese sesgo se traduce en 535,2 mm recomendados frente a 528,7 mm de referencia en los mismos días, un 1,2 % más, y esta cifra debe tenerse presente si el sistema se utiliza para planificar volúmenes.

Los valores absolutos del MAE no deben compararse sin más entre periodos, porque la necesidad de septiembre es cinco veces menor que la de agosto. En términos relativos, el error acumulado equivale al 10,3 % de la necesidad de referencia en desarrollo y al 8,0 % en la prueba, una diferencia mucho menor de lo que sugieren los 0,417 y 0,090 mm de la Tabla 5.4. El MAE se ha mantenido como métrica principal por su interpretación directa en milímetros y su menor sensibilidad a valores extremos (Willmott & Matsuura, 2005), y se acompaña del RMSE precisamente para no ocultar los errores grandes.

5.3.4. Error según el horizonte de planificación

Cuando el usuario planifica varios días, el sistema no recibe observaciones nuevas y el error crece con la anticipación. La Figura 5.4 y la Tabla 5.5 comparan la vía del sistema con una persistencia extendida, que repite la última necesidad conocida durante todo el horizonte y es el punto de partida habitual en predicción de series temporales (Hyndman & Athanasopoulos, 2021). La simulación empieza el 16 de mayo para disponer de historia suficiente en todas las ventanas. Por eso su día 1 de desarrollo y la Tabla 5.4 usan muestras diferentes; en prueba coinciden las 23 emisiones.

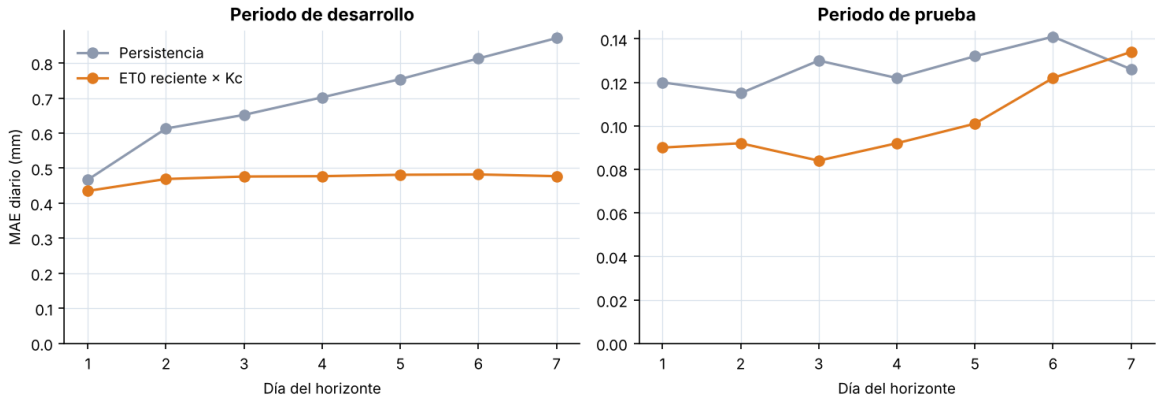


Figura 5.4. MAE diario según el día del horizonte en los periodos de desarrollo y prueba.

Tabla 5.5. MAE diario según el día del horizonte (mm/día).

Día del horizonte	Persistencia, desarrollo	DSS, desarrollo	Persistencia, prueba	DSS, prueba
1	0,467	0,435	0,120	0,090
2	0,613	0,469	0,115	0,092
3	0,652	0,476	0,130	0,084
4	0,702	0,477	0,122	0,092
5	0,754	0,481	0,132	0,101
6	0,813	0,482	0,141	0,122
7	0,871	0,477	0,126	0,134

En el periodo de desarrollo el error de la persistencia casi se duplica entre el primer y el séptimo día, mientras que el del sistema se mantiene entre 0,44 y 0,48 mm. Al separar los casos se aprecian dos causas. Cuando el horizonte cruza un cambio de fase, lo que ocurre en el 4 % de las

emisiones a un día y en el 25 % a siete días, la persistencia comete un error medio de unos 1,6 mm y el sistema de 0,33 a 0,43 mm. Cuando no lo cruza, la persistencia pasa de 0,42 a 0,63 mm entre el primer y el séptimo día y el sistema de 0,44 a 0,51 mm, porque la media de siete días filtra las oscilaciones de un día concreto y representa mejor el nivel de demanda de los días siguientes. En ese último subconjunto la persistencia es ligeramente mejor a un día, con 0,42 frente a 0,44 mm, de modo que la ventaja del sistema en el primer día procede sobre todo de los cambios de fase. En la prueba el comportamiento es distinto. Septiembre tiene un Kc constante y una ET0 en descenso continuo, de modo que ninguna de las dos vías dispone de información sobre esa tendencia. El sistema mantiene la ventaja hasta el quinto día, la reduce en el sexto y pierde frente a la persistencia en el séptimo, con 0,134 frente a 0,126 mm.

El horizonte de siete días se ofrece como planificación orientativa, aunque el séptimo día de prueba pierde frente a la persistencia. Asignar confianza baja desde el cuarto día es una precaución de la interfaz, no un umbral calibrado estadísticamente. La regla R9 muestra el MAE histórico por día del horizonte; no representa un intervalo individual ni garantiza ese error en otra campaña. Para anticipar cambios meteorológicos se necesita una ET0 prevista validada.

5.3.5. Coherencia semanal

Muchas decisiones de riego, como los turnos de una comunidad o la solicitud de agua, se toman a escala semanal. Se agregaron por ello las recomendaciones diarias en semanas naturales de lunes a domingo y se compararon con la referencia. Se consideraron solo las diecinueve semanas completas; las dos semanas de julio afectadas por fechas sin datos se excluyeron para no comparar totales con un número distinto de días.

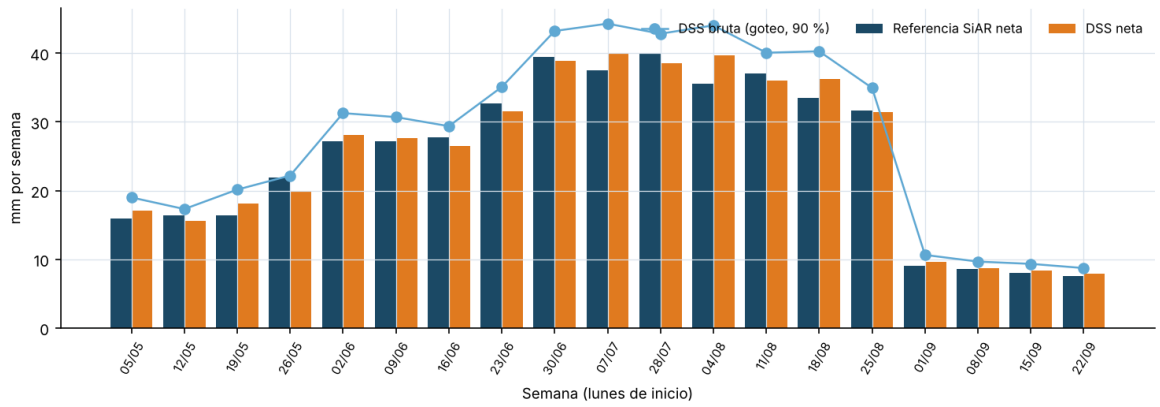


Figura 5.5. Necesidad neta semanal planificada por el DSS frente a la referencia SiAR y dosis bruta para riego por goteo.

El error absoluto medio semanal es de 1,21 mm, con un máximo de 4,10 mm, lo que equivale a un 4,8 % de la necesidad total de esas semanas. Las mayores diferencias aparecen en las semanas que comienzan el 7 de julio y el 4 y el 18 de agosto, con 2,32, 4,10 y 2,73 mm, cuando la necesidad semanal se sitúa entre 33 y 40 mm y la ET0 cambia de forma apreciable de una

semana a otra. La Figura 5.5 permite comprobar también que la dosis bruta mantiene siempre la proporción fijada por la eficiencia y que la caída de septiembre se refleja desde la primera semana del mes.

Además de la exactitud, se verificó la coherencia interna. En todas las consultas comprobadas la suma de las dosis diarias coincide con el total del resumen y el volumen coincide con diez metros cúbicos por milímetro y hectárea. A lo largo de la campaña no se generó ninguna dosis negativa.

5.3.6. Sensibilidad a la eficiencia del riego

La eficiencia modifica la dosis bruta. La Tabla 5.6 utiliza los 531,05 mm netos de los 148 días con referencia válida. No imputa las tres fechas ausentes ni los dos registros sin ET0, por lo que no representa el total íntegro de los 153 días de calendario.

Tabla 5.6. Dosis bruta de los 148 días con referencia válida según el sistema de riego.

Sistema	Eficiencia	Dosis bruta (mm)	Volumen (m3/ha)
Goteo	0,90	590,1	5.901
Aspersión	0,75	708,1	7.081
Superficie	0,60	885,1	8.851

Con la misma necesidad del cultivo, pasar del riego por goteo al de superficie supone aplicar un 50 % más de agua. Una desviación de diez puntos en la eficiencia introducida, por ejemplo usar 0,90 cuando la instalación real trabaja a 0,80, genera un error de alrededor del 12 % en la dosis bruta, bastante mayor que el error de estimación de la necesidad neta medido en los apartados anteriores. Esta comparación sitúa las prioridades de mejora: en una explotación real, medir la eficiencia y la uniformidad de la instalación aportaría más precisión que refinar el modelo de ET0 (Burt et al., 1997). También recuerda que una dosis menor no equivale a un ahorro neto de agua a escala de cuenca, porque parte de las pérdidas en parcela retorna al sistema hidrológico (Perry, 2007).

5.3.7. Escenarios de robustez y trazabilidad

El último bloque de la validación sometió al sistema a situaciones en las que una recomendación incorrecta podría causar daños o confusión. Se definieron trece escenarios con un comportamiento esperado fijado de antemano; los resultados se guardan en docs/data_samples/dss_scenarios_5_3.csv y se resumen en la Tabla 5.7.

Tabla 5.7. Escenarios de validación del comportamiento del sistema.

Escenario	Comportamiento esperado	Resultado observado
Lluvia observada superior a la ETc (23/05)	Dosis nula, nunca negativa	Necesidad de 0,00 mm por la regla R4
Lluvia prevista de 12 mm con probabilidad del 80 %	Aviso sin descuento automático	Se recomienda aplazar y la dosis no cambia
Cinco fechas sin meteorología (18 a 22/07)	Sustitución explícita y aviso	Se usa la ET0 reciente, con aviso en cada día
Emisión el 21/07 con el último dato del 17/07	Aviso general y confianza baja	Aviso de antigüedad y confianza baja en todo el horizonte
ET0 prevista de 11,5 mm	Aviso de extrapolación	Se marca como extrapolación
Fechas posteriores al ciclo (1 y 2/10)	Sin recomendación	No se emite dosis
Primer día de campaña sin histórico	Sin recomendación	No se emite dosis
Eficiencia 1,4, horizonte de 10 días, superficie negativa, sistema desconocido	Rechazo con mensaje	Las cuatro entradas se rechazan
Dotación de 20 mm frente a 47,1 mm planificados	Reducción proporcional y aviso	Factor de 0,42 y total de 20 mm
Eficiencias de 0,60 a 1,00	Dosis decreciente con la eficiencia	70,7, 56,6, 47,1 y 42,4 mm semanales
Coherencia entre día, semana y volumen	Sumas consistentes	Coinciden dosis y volumen
Trazabilidad de cada fila	Origen y reglas registrados	Método, reglas, archivo y fecha presentes
Cambio de Kc de 0,70 a 0,90 (01/07)	El calendario corrige la persistencia	Error de 0,35 mm frente a 1,19 mm

Los trece escenarios produjeron el comportamiento esperado. Más que el recuento, interesa lo que estos casos revelan sobre el diseño. En ninguno de ellos el sistema sustituye una ausencia

por un cero ni oculta que ha cambiado de vía de estimación, y en los casos sin información suficiente prefiere no emitir recomendación. Este comportamiento responde a la idea, expuesta en el apartado 2.3, de que la incertidumbre debe formar parte de la salida.

Los trece escenarios se complementan con quince pruebas automáticas del motor. Tras añadir controles de selección de archivos y compatibilidad entre estación y campaña, la suite completa contiene 61 pruebas. También verifica que una planificación no cambie si se alteran datos posteriores a la fecha de emisión.

5.3.8. Rendimiento operativo

Una recomendación de siete días se genera en el entorno de desarrollo en un tiempo de entre 10 y 25 ms, según la ejecución, y la simulación de la campaña completa, con 152 emisiones, tarda alrededor de un segundo. Los valores exactos de cada ejecución se guardan en el informe de validación. Estos tiempos son irrelevantes para el uso previsto y confirman que, con el volumen del piloto, no es necesario recurrir a procesamiento distribuido. El tiempo de respuesta percibido en la aplicación depende sobre todo del dibujo de la interfaz y no del cálculo.

5.3.9. Análisis crítico

El resultado más relevante del capítulo es que el sistema mejora a la referencia predictiva del capítulo 4 sin recurrir a un algoritmo más complejo. La mejora no procede de aprender mejor la serie, sino de separar en la estimación lo que es incierto, la demanda atmosférica, de lo que se conoce de antemano, el calendario del cultivo. Este hallazgo matiza la conclusión del apartado 4.3 en lugar de contradecirla: allí se comprobó que, con un único ciclo, los modelos de aprendizaje no superaban a la persistencia; aquí se comprueba que incorporar conocimiento agronómico explícito sí lo hace. Es un argumento a favor de los sistemas híbridos defendidos en el apartado 2.3, en los que el aprendizaje automático, cuando se disponga de más datos, debería corregir una referencia física y no sustituirla.

Los resultados deben leerse, no obstante, con varias cautelas. La primera es que la referencia es la propia SiAR. Un error pequeño frente a ella indica que el sistema reproduce bien un cálculo oficial, no que la dosis sea la adecuada para una parcela concreta, cuyo suelo, marco de plantación, cubierta y estado del cultivo pueden diferir de las hipótesis de la estación. La segunda es que todo se ha evaluado con una estación, un cultivo y una campaña. La ventaja del sistema en los horizontes largos depende de que existan cambios de fase dentro del horizonte, y en un cultivo con un Kc que varíe de forma gradual sería menor. La tercera es que el tramo de prueba, septiembre, es atípico: tiene un Kc muy bajo, necesidades cercanas a un milímetro y una ET0 en descenso, por lo que sus errores absolutos son pequeños y poco representativos del verano.

La cuarta cautela se refiere a lo que el sistema no hace. No decide cuándo regar, porque sin balance hídrico del suelo todas las necesidades se tratan como diarias. No integra una ET0

prevista contrastada, por lo que en los horizontes largos depende de que el tiempo se mantenga. Y no se ha validado con usuarios, de modo que no hay evidencia de que la interfaz y las explicaciones resulten comprensibles para quienes tendrían que utilizarlas. Hay también situaciones en las que el sistema no debería emitir una recomendación sin que alguien la revise. Ocurre con los datos desactualizados durante más de dos días, cuando la ET0 queda fuera del intervalo observado, ante una previsión de lluvia relevante y siempre que la dotación obliga a recortar la dosis. En todos esos casos el sistema emite avisos, pero la decisión sobre qué hacer con ellos corresponde al usuario.

Con estas limitaciones, el prototipo cumple lo que se pretendía demostrar en este capítulo: que es posible convertir datos agroclimáticos públicos en una recomendación de riego diaria y semanal, explicada, trazable y evaluada frente a una referencia, con un error conocido para cada horizonte. La valoración de este resultado frente a los objetivos del trabajo se desarrolla en el capítulo 6.

5.3.10. Reproducibilidad y evidencias

Las cifras, tablas y figuras de este capítulo se regeneran con:

```
python -m src.analysis.build_validation_5_3

python -m src.visualization.build_dss_visual

python -m unittest discover -s tests
```

El primer comando produce el informe completo (docs/data_samples/dss_validation_5_3.json), los errores por horizonte (dss_horizon_errors_5_3.csv), los escenarios (dss_scenarios_5_3.csv), el ejemplo del apartado 5.2 y las Figuras 5.3, 5.4 y 5.5. El segundo genera la Figura 5.1 y el tercero ejecuta las sesenta y una pruebas automáticas del proyecto. La captura de la Figura 5.2 se obtiene arrancando la aplicación con streamlit run src/dss/app_streamlit.py y abriendo la dirección local con los parámetros ?fecha=2025-06-28&referencia=1.

6. Conclusiones

6.1. Cumplimiento de objetivos y aportaciones

6.1.1. Valoración de los objetivos

El objetivo general del trabajo era diseñar, implementar y evaluar un sistema inteligente de apoyo a la decisión que integrara datos meteorológicos, ambientales, agronómicos e hidrológicos, estimara las necesidades de riego y las transformara en recomendaciones operativas, trazables y comprensibles. Al término del proyecto puede afirmarse que el objetivo se ha alcanzado como prueba de concepto y dentro de un caso acotado. El repositorio contiene una cadena reproducible que parte de observaciones y necesidades de SiAR y termina en una recomendación diaria y semanal, explicada y evaluada frente a una referencia oficial. AEMET se extrajo y normalizó, pero su emisión de 2026 no alimenta el motor evaluado con 2025. Esa afirmación tiene un límite preciso: se ha demostrado con una estación, un cultivo y una campaña, y frente a una necesidad calculada, no frente al riego aplicado ni a la respuesta del cultivo. La dimensión hidrológica del objetivo, además, se ha resuelto mediante una dotación que introduce el usuario y no mediante datos oficiales de disponibilidad de agua.

Para valorar los objetivos específicos se ha seguido un criterio deliberadamente estricto. Un objetivo se considera cumplido cuando existe un resultado implementado, reproducible desde el repositorio y evaluado en esta memoria. Se considera parcial cuando alguna parte de su formulación en el apartado 1.2 no se ha abordado o se ha sustituido por una alternativa más limitada, aunque la sustitución esté justificada. La Tabla 6.1 recoge la valoración.

Tabla 6.1. Grado de cumplimiento de los objetivos específicos.

Objetivo específico (apartado 1.2)	Evidencia principal	Grado	Alcance y desviaciones
Identificar y documentar las fuentes y variables del problema	Apartado 3.1; inventarios de SiAR y AEMET	Parcial	SiAR y AEMET documentadas e integradas. Los datos hidrológicos del MITECO se analizaron y se descartaron por su escala de embalse y cuenca (apartado 5.1.4).
Diseñar un flujo de datos reproducible con calidad y trazabilidad	Apartado 4.1; capas raw, interim y processed	Cumplido	Controles de calidad que no destruyen el dato original y procedencia hasta el archivo raw. El almacenamiento es local; MySQL y Apache Hop quedan como arquitectura objetivo (apartado 3.2.2).

Objetivo específico (apartado 1.2)	Evidencia principal	Grado	Alcance y desviaciones
Realizar el análisis exploratorio y construir variables derivadas	Apartado 4.2; catálogo de 88 variables	Parcial	Cobertura, calidad y disponibilidad temporal de cada variable caracterizadas. Con un cultivo, una localización y sin datos de disponibilidad de agua, solo puede estudiarse la relación entre meteorología, fase del cultivo y demanda.
Desarrollar y comparar modelos predictivos	Apartado 4.3; seis enfoques con validación temporal	Cumplido	Comparación con métricas objetivas y prueba reservada. Ningún algoritmo de aprendizaje supera de forma estable a la persistencia.
Diseñar una lógica de recomendación sobre cantidad y momento de riego	Apartado 5.1; motor con reglas R1 a R10	Parcial	Resuelve cuánto regar a escala diaria y semanal, con eficiencia y dotación. El momento solo se trata mediante avisos de aplazamiento: sin balance hídrico del suelo no puede decidirse cuándo regar.
Implementar un prototipo de aplicación o panel de visualización	Apartado 5.2; aplicación en Streamlit y línea de comandos	Cumplido	Aplicación funcional y reproducible. Cultivo y estación fijados en el caso piloto; Power BI o Tableau sustituidos de forma justificada; sin evaluación con usuarios.
Evaluar el funcionamiento integral del sistema	Apartado 5.3; validación, 13 escenarios y 61 pruebas automáticas	Cumplido	Comparación con la referencia SiAR y con la persistencia, error por horizonte, coherencia semanal y robustez. Validación técnica, no externa ni de campo.

El balance es de cuatro objetivos cumplidos y tres parciales. Las desviaciones no tienen una única causa: faltan datos hidrológicos y de parcela, diversidad de campañas y cultivos y, para decidir el momento del riego, implementar un balance hídrico del suelo. El motor ya admite como entradas la eficiencia, la dotación y una ET0 prevista, pero incorporar propiedades del suelo y riegos aplicados requiere ampliar tanto los datos como la lógica de decisión. Estas limitaciones ordenan las líneas de mejora del apartado 6.3.

6.1.2. Aportaciones del trabajo

La aportación principal es un resultado empírico que no estaba previsto en el anteproyecto. En este piloto, para anticipar la necesidad de riego de un cultivo con calendario definido, separar la estimación en sus dos componentes resultó más eficaz que aumentar la complejidad del modelo. Uno de ellos, la demanda atmosférica, es incierto pero evoluciona de forma gradual; el otro, el

coeficiente de cultivo, cambia de forma brusca pero se conoce de antemano. La vía que multiplica la ET0 media de los siete días anteriores por el Kc del día objetivo reduce el MAE de la recomendación a un día frente a la persistencia en un 7 % en desarrollo y en un 25 % en la prueba, y el RMSE de desarrollo en un 18 %. La diferencia se amplía con la anticipación: a siete días, en el periodo de desarrollo, el error del sistema es de 0,48 mm frente a 0,87 mm de la persistencia, porque se mantiene prácticamente estable a lo largo del horizonte. Donde el método se distingue con más claridad es en los cambios de fase. El 1 de septiembre, cuando el Kc pasa de 1,00 a 0,30, la persistencia se desvía 3,52 mm y el sistema 0,01 mm.

La segunda aportación es un resultado negativo bien acotado. Seis enfoques, desde la persistencia hasta XGBoost, se compararon sobre la misma variable objetivo, los mismos cortes temporales y una prueba reservada que no intervino en la selección. Los cinco algoritmos de aprendizaje utilizaron el conjunto de variables definido en el apartado 4.3; la persistencia utilizó el último valor observado. Ninguno de los algoritmos de aprendizaje superó de forma estable a esta referencia sencilla. Este resultado no resta valor al trabajo. Es coherente con lo expuesto en el apartado 2.2: con un único ciclo de 148 observaciones y una necesidad neta muy relacionada con el calendario del cultivo (su correlación con el Kc es de 0,93), los modelos más complejos no disponen de diversidad suficiente para demostrar una mejora estable. La fiabilidad de la comparación descansa en dos decisiones documentadas. La primera fue excluir la ET0, la ETc y la precipitación efectiva del mismo día, que habrían permitido reconstruir el objetivo de forma algebraica y producir métricas aparentemente excelentes. La segunda, seleccionar el enfoque antes de consultar la prueba final para esa comparación. El método ET0 reciente por Kc se evaluó después reutilizando septiembre; no es otra validación independiente. Leídos conjuntamente, los capítulos 4 y 5 respaldan el planteamiento híbrido del apartado 2.3: con pocos datos, el conocimiento agronómico explícito aporta más que el algoritmo, y el aprendizaje automático encuentra su lugar como corrección de una referencia física, no como sustituto de ella.

La tercera aportación es de diseño. El motor hace visibles sus limitaciones en la salida. Cada recomendación indica el método que la produjo, las reglas aplicadas, el último dato observado, un nivel de confianza y, cuando está disponible el informe de validación, el error medio para su día del horizonte. Si falta información imprescindible no se emite una dosis; si los datos son antiguos, se conserva la estimación con un aviso y confianza baja. Las filas sin estimación permanecen ausentes, no se convierten en dosis cero, y ninguna dosis emitida resulta negativa. Las pruebas automáticas verifican, además, que la planificación no cambia cuando se alteran los datos posteriores a la fecha de emisión, que es la garantía formal de que el sistema no utiliza información futura.

La cuarta aportación es la reproducibilidad. El repositorio conserva los datos del piloto, los informes de evaluación y los módulos que generan las principales evidencias cuantitativas y visualizaciones de los capítulos 4 y 5; el README documenta los comandos separados para

ejecutar cada fase. Las sesenta y una pruebas automáticas se han ejecutado correctamente en el entorno local del proyecto y el motor de recomendación puede utilizar el CSV oficial versionado sin nuevas credenciales. Así, el lector puede comprobar la correspondencia entre la memoria y el código, siempre que disponga de las dependencias indicadas.

6.2. Limitaciones e impacto del proyecto

6.2.1. Limitaciones y alcance de las conclusiones

Las limitaciones del piloto se han señalado a lo largo de los capítulos anteriores. Reunidas, permiten delimitar qué conclusiones son válidas y cuáles no pueden extraerse todavía. Se agrupan a continuación en cinco tipos, según la validez que comprometen, y la Tabla 6.2 relaciona cada una con la afirmación que impide y con la línea de mejora que la aborda.

La limitación más importante es de validez de constructo. La variable objetivo y la referencia de toda la evaluación es la necesidad neta calculada por SiAR, que aplica la metodología FAO-56 a las condiciones de una estación y a un calendario de cultivo estándar (Allen et al., 1998). Un error pequeño frente a ella demuestra que el sistema reproduce y anticipa bien un cálculo oficial, no que la dosis sea la adecuada para una parcela concreta, cuyo suelo, cubierta, marco de plantación y estado del cultivo pueden diferir de los supuestos de la estación.

La segunda es de validez externa. Todo se ha evaluado con una estación, un cultivo y una campaña. El calendario del pimiento, con saltos bruscos del Kc entre fases, favorece precisamente al método propuesto, cuya ventaja sería menor en un cultivo con un coeficiente que varíe de forma gradual. El tramo de prueba, septiembre, es además atípico: sus necesidades rondan 1 mm diario, por lo que sus errores absolutos son poco representativos del verano.

La tercera afecta a la capacidad predictiva. El sistema no dispone de una ET0 prevista contrastada. AEMET está integrado y normalizado, pero sus predicciones no coinciden temporalmente con la campaña de 2025, y sin un histórico de emisiones no es posible calibrar ni evaluar una ET0 futura sin incurrir en fuga de información. En consecuencia, en cualquier horizonte futuro la recomendación depende de que el tiempo no cambie demasiado; el cuarto día solo activa un aviso prudencial, y en la prueba el sistema llega a perder frente a la persistencia en el séptimo día. Tampoco descuenta la lluvia prevista. Es una decisión prudente en un clima con 2,51 mm de precipitación efectiva en toda la campaña, pero en zonas más lluviosas trasladaría al usuario un número mayor de avisos que resolver.

La cuarta es funcional. El sistema decide cuánto regar, pero no cuándo, porque sin balance hídrico del suelo trata todas las necesidades como diarias. La restricción de agua se aplica mediante una reducción proporcional, que no reparte el déficit según la sensibilidad de cada fase del cultivo (Fereres & Soriano, 2007). La aplicación, por su parte, trabaja con un caso fijo, no conserva un histórico de consultas y no se ha probado con agricultores ni técnicos.

La quinta es de arquitectura y supone una desviación respecto al anteproyecto. MySQL, Apache Hop, Docker y PySpark no se han implementado, y el cuadro de mando en Power BI o Tableau se ha sustituido por una aplicación en Streamlit. Las razones se exponen en los apartados 3.2.2 y 5.2.1 y son defendibles para el volumen del piloto, pero deben declararse como lo que son: el prototipo demuestra el flujo de datos y de decisión, no una plataforma desplegable.

Tabla 6.2. Limitaciones del piloto, alcance de las conclusiones y línea de mejora asociada.

Limitación	Qué no puede afirmarse todavía	Línea de mejora
Referencia calculada por SiAR, sin riego aplicado ni respuesta del cultivo	Que las dosis sean óptimas para una parcela ni que reduzcan el consumo de agua	Validación en campo (6.3.3)
Una estación, un cultivo y una campaña	Que los resultados se generalicen a otras zonas, cultivos o años	Ampliación de la evidencia (6.3.1)
Sin ET0 prevista ni histórico de predicciones	Que el sistema anticipe cambios de tiempo en los horizontes largos	ET0 prevista (6.3.2)
Sin balance hídrico del suelo	Que el sistema determine el momento adecuado del riego	Balance hídrico y riego deficitario (6.3.2)
Restricción hídrica introducida como dotación del usuario	Que la recomendación refleje la disponibilidad oficial de agua	Indicadores hidrológicos (6.3.4)
Interfaz sin evaluación con usuarios	Que las recomendaciones se comprendan y se adopten	Evaluación con usuarios (6.3.3)
Arquitectura objetivo no implementada	Que el prototipo pueda operar de forma continua	Evolución de la plataforma (6.3.4)

6.2.2. Impacto del proyecto

El impacto debe valorarse con la misma prudencia. El trabajo no ha demostrado ahorro de agua, y no podía hacerlo con el diseño adoptado. Conviene recordar, además, que una dosis menor en parcela no equivale necesariamente a un ahorro neto a escala de cuenca, porque parte de las pérdidas retorna al sistema hidrológico (Perry, 2007). Con esa salvedad, el proyecto tiene tres resultados observables en el prototipo y un impacto potencial, todavía no medido en campo.

El primero es una capacidad funcional comprobada. El sistema transforma datos públicos y gratuitos en una dosis diaria y semanal expresada en milímetros y en metros cúbicos por parcela, acompañada de su explicación y sin necesidad de sensores. Su valor práctico se concentra en los

cambios de fase. En la semana analizada en el apartado 5.2.3, la persistencia habría planificado 6,77 mm menos de los que necesitó el cultivo, un 18 % de la referencia, justo al entrar en una fase de mayor demanda; el sistema se desvió un 4,9 %. Es el tipo de error que un calendario fijo o la repetición de la última dosis no ponen de manifiesto y que podría producir un déficit si se aplicara sin otros controles; el ejemplo retrospectivo no demuestra que ocurriera en una parcela.

El segundo es un hallazgo que reordena las prioridades de mejora. El análisis de sensibilidad mostró que un error de diez puntos en la eficiencia de la instalación produce una desviación de alrededor del 12 % en la dosis bruta, muy superior al error de estimación de la necesidad neta medido en este trabajo. Para una explotación, caracterizar la eficiencia y la uniformidad de su instalación aportaría más precisión que refinar el modelo de ET0 (Burt et al., 1997). La observación es pertinente también para las políticas de digitalización del regadío (Real Decreto 854/2022, 2022): una herramienta digital solo convierte su precisión en ahorro si conoce la instalación sobre la que se aplica.

El tercero es metodológico. El repositorio constituye una plantilla reutilizable para otros cultivos y estaciones, porque la configuración del caso, la ETL y el motor están desacoplados. Además, documenta con evidencias reproducibles una advertencia que la literatura formula en términos generales: la elección del algoritmo depende del tamaño y la estructura de los datos, y los modelos complejos deben contrastarse con líneas base sencillas antes de adoptarse (Benos et al., 2021; Liakos et al., 2018).

El impacto potencial depende de la adopción. La trayectoria de los sistemas de apoyo a la decisión agrícola muestra que muchas herramientas técnicamente correctas no llegan a utilizarse (McCown, 2002), y que la confianza, la facilidad de uso y la relevancia percibida condicionan su adopción (Rose et al., 2016). El prototipo responde a esas condiciones con explicaciones en lenguaje llano, avisos visibles y un formato numérico adaptado al usuario español, pero mientras no se evalúe con usuarios reales su efecto sobre la toma de decisiones sigue siendo una hipótesis.

6.3. Mejoras y líneas futuras

Las líneas de mejora se presentan en el orden en que deberían abordarse, porque cada una condiciona la validez de la siguiente. No tendría sentido, por ejemplo, entrenar modelos más complejos antes de ampliar los datos, ni medir ahorros antes de disponer de registros de riego. Este orden es coherente con la conclusión del apartado 4.3: la principal limitación del proyecto es la cobertura de los datos, no la falta de algoritmos.

6.3.1. Ampliación de la evidencia

La primera mejora consiste en ampliar los datos con varias campañas, estaciones de Almería y cultivos. La extracción meteorológica admite estación y periodo; las necesidades se aportan mediante un CSV SiAR y metadatos. La ETL ya exige selección explícita cuando hay varios

archivos y rechaza estaciones o campañas incompatibles. Falta un catálogo seleccionable en la interfaz y comprobar la aplicabilidad agronómica de cada calendario. Con más campañas podrán reservarse bloques completos para evaluar generalización temporal y espacial (Roberts et al., 2017).

6.3.2. Mejora del motor de recomendación

Una mejora prioritaria para anticipar cambios de tiempo es incorporar una ET0 prevista, especialmente en los días 4 a 7 del horizonte. El motor ya admite esta entrada, de modo que el trabajo pendiente es de datos y de evaluación. La predicción municipal de AEMET OpenData describe los días posteriores a cada emisión y el proyecto no dispone de emisiones pasadas, por lo que el histórico debe construirse archivando de forma programada cada predicción. Con ese histórico podrán compararse dos alternativas: estimar la ET0 con la ecuación de Hargreaves calibrada frente a la ET0 de Penman-Monteith observada en la estación (Allen et al., 1998), o estudiar el pronóstico de necesidades netas que publica SiAR, calculado con previsiones de ET0 y lluvia de AEMET. Este último cubre seis días (Sistema de Información Agroclimática para el Regadío, s. f.), por lo que no resuelve por sí solo el séptimo día del horizonte del DSS. Además, si se usa como entrada, su comparación con la referencia SiAR debe declararse como contraste entre productos relacionados, no como validación independiente. Cualquiera de estas vías debe evaluarse con la misma disciplina temporal que el resto del trabajo, utilizando solo predicciones emitidas antes de cada fecha objetivo, y sustituir a la vía actual únicamente si mejora el error por horizonte de la Tabla 5.5. El mismo archivo permitirá evaluar si conviene descontar la lluvia prevista en lugar de limitarse a avisar.

Una vez ampliados los datos, el aprendizaje automático debería reintroducirse con un papel distinto al del capítulo 4: no para predecir directamente la necesidad, sino para aprender la corrección de la estimación física, es decir, el residuo entre la vía ET0 × Kc y la referencia, a partir de las variables meteorológicas y de predicción disponibles en el momento de emitir. Este planteamiento conserva la explicabilidad de la base agronómica y reduce el riesgo de sobreajuste. En paralelo, los niveles de confianza actuales, definidos mediante reglas a partir del error medio por horizonte, deberían sustituirse por intervalos de predicción, de forma que cada dosis se acompañe de un rango cuantificado (Hyndman & Athanasopoulos, 2021).

La tercera mejora del motor es un balance hídrico del suelo con agotamiento admisible, como el propuesto en FAO-56 (Allen et al., 1998). Permitiría decidir no solo cuánto sino cuándo regar y aprovechar la lluvia realmente almacenada en el suelo. Requiere la capacidad de retención, la profundidad radicular y el registro de riegos de cada parcela. Con esa información, la reducción proporcional por dotación podría sustituirse por una estrategia de riego deficitario que concentre el déficit en las fases menos sensibles del cultivo (Fereres & Soriano, 2007).

6.3.3. Validación en condiciones de uso

Antes de cualquier despliegue es necesario evaluar el prototipo con técnicos de cooperativas y agricultores, mediante tareas concretas de interpretación y decisión y con medidas de comprensión, utilidad percibida y confianza (Rose et al., 2016). Esta evaluación puede realizarse con la aplicación actual y respondería a una pregunta que el trabajo no ha podido contestar: si las explicaciones y los avisos resultan útiles a quienes deben decidir.

La única forma de cuantificar el ahorro de agua o el efecto sobre la producción es un ensayo en campo que registre el riego aplicado, la humedad del suelo y el rendimiento en parcelas que sigan la recomendación y en parcelas de control. El sistema ya exporta cada recomendación con sus parámetros y su origen, de manera que el archivo de recomendaciones emitidas puede compararse directamente con el riego real. Solo entonces podrá sustituirse la referencia calculada por una referencia medida y evaluarse el sistema frente al problema que motivó el trabajo.

6.3.4. Evolución de la plataforma

La industrialización del prototipo debería abordarse cuando las mejoras anteriores justifiquen un uso continuado. Comprende persistir catálogos, recomendaciones y metadatos en la base de datos relacional prevista en el apartado 3.2.2, programar la ingesta diaria con un orquestador, que puede ser Apache Hop u otra herramienta equivalente, empaquetar el sistema con Docker y permitir que la aplicación seleccione estación y cultivo entre los casos declarados. Los indicadores del Boletín Hidrológico del MITECO pueden incorporarse como contexto a escala de cuenca, para advertir de situaciones de escasez, sin pretender deducir de ellos la dotación de una parcela. El procesamiento distribuido con PySpark solo estaría justificado si el sistema se extendiera a escala nacional; con el volumen actual añadiría complejidad sin un beneficio demostrable, como se señaló en el apartado 3.2.4.

6.3.5. Consideración final

El trabajo se planteó como la construcción de una cadena completa de datos y decisión, con el aprendizaje automático como uno de sus componentes. El piloto obliga a reconsiderar el papel de ese componente. Con los datos disponibles, la mejora no ha procedido del algoritmo, sino de estructurar correctamente el problema: separar lo incierto de lo conocido, impedir que la información futura contamine la evaluación y hacer visible la incertidumbre en lugar de esconderla. El aprendizaje automático conserva su lugar en el sistema, pero como herramienta para corregir una base física cuando existan datos suficientes, no como sustituto de ella. La frontera de mejora del proyecto no está, por tanto, en el modelo, sino en los datos: más campañas, predicciones archivadas y, sobre todo, información medida en las parcelas en las que se toma la decisión.

Referencias bibliográficas

Agencia Estatal de Meteorología. (s. f.). *AEMET OpenData*. Recuperado el 16 de septiembre de 2026, de https://opendata.aemet.es/centrodedescargas/inicio

Allen, R. G., Pereira, L. S., Raes, D., & Smith, M. (1998). *Crop evapotranspiration: Guidelines for computing crop water requirements* (FAO Irrigation and Drainage Paper No. 56). Food and Agriculture Organization of the United Nations. https://www.fao.org/4/x0490e/x0490e00.htm

Benos, L., Tagarakis, A. C., Dolias, G., Berruto, R., Kateris, D., & Bochtis, D. (2021). Machine learning in agriculture: A comprehensive updated review. *Sensors, 21*(11), 3758. https://doi.org/10.3390/s21113758

Brouwer, C., Prins, K., & Heibloem, M. (1989). *Irrigation water management: Irrigation scheduling* (Training manual No. 4). Food and Agriculture Organization of the United Nations. https://www.fao.org/4/t7202e/t7202e00.htm

Burt, C. M., Clemmens, A. J., Strelkoff, T. S., Solomon, K. H., Bliesner, R. D., Hardy, L. A., Howell, T. A., & Eisenhauer, D. E. (1997). Irrigation performance measures: Efficiency and uniformity. *Journal of Irrigation and Drainage Engineering, 123*(6), 423–442. https://doi.org/10.1061/(ASCE)0733-9437(1997)123:6(423)

European Environment Agency. (2021). *Water resources across Europe—Confronting water stress: An updated assessment* (EEA Report No. 12/2021). https://www.eea.europa.eu/publications/water-resources-across-europe-confronting-water-stress

Fereres, E., & Soriano, M. A. (2007). Deficit irrigation for reducing agricultural water use. *Journal of Experimental Botany, 58*(2), 147–159. https://doi.org/10.1093/jxb/erl165

Food and Agriculture Organization of the United Nations. (2021). *The state of the world's land and water resources for food and agriculture—Systems at breaking point*. https://doi.org/10.4060/cb7654en

Fountas, S., Carli, G., Sørensen, C. A. G., Tsiropoulos, Z., Cavalaris, C., Vatsanidou, A., Liakos, B., Canavari, M., Wiebensohn, J., & Tisseyre, B. (2015). Farm management information systems: Current situation and future perspectives. *Computers and Electronics in Agriculture, 115*, 40–50. https://doi.org/10.1016/j.compag.2015.05.011

Gebbers, R., & Adamchuk, V. I. (2010). Precision agriculture and food security. *Science, 327*(5967), 828–831. https://doi.org/10.1126/science.1183899

Howell, T. A. (2001). Enhancing water use efficiency in irrigated agriculture. *Agronomy Journal, 93*(2), 281–289. https://doi.org/10.2134/agronj2001.932281x

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Intergovernmental Panel on Climate Change. (2022). *Climate change 2022: Impacts, adaptation and vulnerability* (H.-O. Pörtner, D. C. Roberts, M. Tignor, E. S. Poloczanska, K. Mintenbeck, A. Alegría, M. Craig, S. Langsdorf, S. Löschke, V. Möller, A. Okem, & B. Rama, Eds.). Cambridge University Press. https://doi.org/10.1017/9781009325844

Liakos, K. G., Busato, P., Moshou, D., Pearson, S., & Bochtis, D. (2018). Machine learning in agriculture: A review. *Sensors, 18*(8), 2674. https://doi.org/10.3390/s18082674

Lindblom, J., Lundström, C., Ljung, M., & Jonsson, A. (2017). Promoting sustainable intensification in precision agriculture: Review of decision support systems development and strategies. *Precision Agriculture, 18*(3), 309–331. https://doi.org/10.1007/s11119-016-9491-4

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems, 30*, 4765–4774. https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

McCown, R. L. (2002). Locating agricultural decision support systems in the troubled past and socio-technical complexity of 'models for management'. *Agricultural Systems, 74*(1), 11–25. https://doi.org/10.1016/S0308-521X(02)00020-3

Ministerio de Agricultura, Pesca y Alimentación. (s. f.). *Sistema de Información Agroclimática para el Regadío (SiAR)*. Recuperado el 16 de septiembre de 2026, de https://servicio.mapa.gob.es/siarweb/

Ministerio para la Transición Ecológica y el Reto Demográfico. (s. f.). *El Boletín Hidrológico semanal*. Recuperado el 16 de septiembre de 2026, de https://www.miteco.gob.es/es/agua/temas/evaluacion-de-los-recursos-hidricos/boletin-hidrologico.html

Navarro-Hellín, H., Martínez-del-Rincón, J., Domingo-Miguel, R., Soto-Valles, F., & Torres-Sánchez, R. (2016). A decision support system for managing irrigation in agriculture. *Computers and Electronics in Agriculture, 124*, 121–131. https://doi.org/10.1016/j.compag.2016.04.003

Perry, C. (2007). Efficient irrigation; inefficient communication; flawed recommendations. *Irrigation and Drainage, 56*(4), 367–378. https://doi.org/10.1002/ird.323

Real Decreto 854/2022, de 11 de octubre, por el que se crean la Mesa Nacional del Regadío y el Observatorio de la Sostenibilidad del Regadío. *Boletín Oficial del Estado*, 245, de 12 de octubre de 2022, 139046–139055. https://www.boe.es/eli/es/rd/2022/10/11/854

Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Arroita, G., Hauenstein, S., Lahoz-Monfort, J. J., Schröder, B., Thuiller, W., Warton, D. I., Wintle, B. A., Hartig, F., & Dormann, C. F. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography, 40*(8), 913–929. https://doi.org/10.1111/ecog.02881

Rose, D. C., Sutherland, W. J., Parker, C., Lobley, M., Winter, M., Morris, C., Twining, S., Ffoulkes, C., Amano, T., & Dicks, L. V. (2016). Decision support tools for agriculture: Towards effective design and delivery. *Agricultural Systems, 149*, 165–174. https://doi.org/10.1016/j.agsy.2016.09.009

Shim, J. P., Warkentin, M., Courtney, J. F., Power, D. J., Sharda, R., & Carlsson, C. (2002). Past, present, and future of decision support technology. *Decision Support Systems, 33*(2), 111–126. https://doi.org/10.1016/S0167-9236(01)00139-7

Sistema de Información Agroclimática para el Regadío (SiAR). (s. f.). *Manual de uso de la web SiAR*. https://servicio.mapa.gob.es/siarweb/documentos/manuales/ManualUsoWebSiAR.pdf

Streamlit. (2024). *Streamlit* (Versión 1.39.0) [Software]. https://streamlit.io

Willmott, C. J., & Matsuura, K. (2005). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research, 30*(1), 79–82. https://doi.org/10.3354/cr030079

Wolfert, S., Ge, L., Verdouw, C., & Bogaardt, M.-J. (2017). Big Data in smart farming—A review. *Agricultural Systems, 153*, 69–80. https://doi.org/10.1016/j.agsy.2017.01.023

Zhai, Z., Martínez, J. F., Beltran, V., & Martínez, N. L. (2020). Decision support systems for agriculture 4.0: Survey and challenges. *Computers and Electronics in Agriculture, 170*, 105256. https://doi.org/10.1016/j.compag.2020.105256

Zhang, N., Wang, M., & Wang, N. (2002). Precision agriculture—A worldwide overview. *Computers and Electronics in Agriculture, 36*(2–3), 113–132. https://doi.org/10.1016/S0168-1699(02)00096-0

Anexo A. Reproducción y localización de las evidencias

El código, los datos de muestra y las salidas de evaluación del piloto se organizan en el repositorio https://github.com/al1sr/tfm-regadio-dss. Las rutas de este anexo son relativas a su raíz. Para repetir las pruebas sin credenciales es suficiente utilizar el CSV de necesidades hídricas versionado; las nuevas consultas a las APIs requieren tokens personales guardados fuera del control de versiones.

A.1. Archivos principales

Tabla A.1. Rutas del repositorio para reproducir y contrastar los resultados.

Etapa	Código y evidencia
Extracción y transformación	src/data/: extract_pilot.py, transform_interim.py docs/data_samples/: etl_volume_summary_4_1.csv
EDA y variables	src/analysis/: build_eda_4_2.py docs/data_samples/: feature_catalog_4_2.csv
Comparación de modelos	src/models/: train_evaluate.py docs/data_samples/: model_evaluation_4_3.json
Recomendación y validación	src/dss/: engine.py src/analysis/: build_validation_5_3.py docs/data_samples/: dss_validation_5_3.json scripts/demo_local.py y docs/DEMO_TFM.md
Pruebas automáticas	tests/

A.2. Secuencia mínima de reproducción

Desde la raíz del repositorio, tras crear un entorno virtual e instalar requirements.txt, los siguientes comandos regeneran las auditorías, las comparaciones y la validación sin necesidad de consultar de nuevo los servicios externos:

```
python -m src.analysis.build_etl_audit_4_1
python -m src.analysis.build_eda_4_2
python -m src.models.train_evaluate
python -m src.analysis.build_validation_5_3
python -m unittest discover -s tests
```

La demostración local sin nuevas consultas a las API se abre con python -m scripts.demo_local y se explica en docs/DEMO_TFM.md. La aplicación Streamlit también se abre con streamlit run src/dss/app_streamlit.py si esa dependencia está instalada. Sus recomendaciones son orientativas: la evaluación publicada utiliza la referencia calculada por SiAR, no mediciones de riego ni resultados de cultivo en parcela.